

Een machine learning benadering voor het identificeren van relevante fysieke spelersattributen in voetbal scouting.

Vanacker Matthijs.

Scriptie voorgedragen tot het bekomen van de graad van
Professionele bachelor in de toegepaste informatica

Promotor: Dhr. T. Antjon

Co-promotor: Dhr. A. Martiny

Academiejaar: 2025–2026

Eerste examenperiode

Departement IT en Digitale Innovatie .

**HO
GENT**

Woord vooraf

Één van mijn grootste passies is voetbal, daarom ging ik bij het zoeken van een onderwerp op zoek naar een opportuniteit binnen deze sector. Ik dacht echter dat de kans dat ik een onderwerp ging vinden relatief klein was.

Toen ik bij KAA Gent de kans kreeg om dit onderwerp te bespreken was ik meteen geïnteresseerd, niet enkel was het een interessant onderwerp in de sportsector maar ook binnen de club waar ik al jarenlang fan ben. Na een positieve bespreking met de club heb ik met mijn promotor de mogelijkheden besproken en zijn we samen tot een concrete onderzoeksvraag gekomen.

Graag wil ik dan ook mijn promotor, Tom Antjon, en co-promotor, Adriaan Martiny, bedanken voor deze opportuniteit. Tijdens de samenwerking werd er altijd duidelijk aangegeven wat goed liep en wat verbeterd kon worden, om zo het project in de juiste richting te sturen.

Ik zou graag ook mijn zus, vader en moeder bedanken voor het altijd steunen van mijn studies en bachelorproef, die altijd vroegen of ze ergens konden helpen en ook klaarstonden indien nodig.

Ik hoop dat dit onderzoek bijdraagt aan waardevolle inzichten in de mogelijkheden van dataverwerking in de sportwereld.

Samenvatting

De moderne voetbalwereld beschikt over enorme hoeveelheden aan data en er wordt altijd gezocht naar nieuwe manieren om deze data te gebruiken om de prestaties van de club te verbeteren. Zo zoekt ook KAA Gent naar allerlei manieren om deze data te gebruiken, een domein waar er nog ruimte is voor verbetering is in het scoutingsdepartement, meer specifiek in het onderzoek naar het belang van fysieke prestaties van spelers bij het behalen van overwinningen.

De huidige methode van het scoren van de fysieke prestaties is gebaseerd op het arbitrair inschatten van het belang van bepaalde fysieke statistieken. Dit is echter een subjectieve en geen objectieve inschatting van de data. Een manier om deze zaken objectiever te beoordelen is het te benaderen vanuit een machine learning-perspectief.

De centrale onderzoeksvraag van dit onderzoek luidt: *Hoe kan een objectieve en reproduceerbare fysieke spelersscore ontwikkeld worden op basis van wedstrijddata met behulp van machine learning-technieken?* Hierbij wordt onderzocht welke methode het beste is om het belang van bepaalde statistieken te bepalen, alsook hoe deze benadering past in de huidige scoutingstructuur.

Het hoofddoel van het onderzoek is het construeren van een fysieke spelersscore gebaseerd op de inzichten van een machine learning-model dat wedstrijdresultaten voorspelt.

De methodologie die in dit onderzoek gehanteerd wordt begint bij een uitgebreide literatuurstudie, waarna een proof-of-concept gecreëerd wordt en wordt toegevoegd aan een alternatieve versie van de huidige scoutingstool binnen de club.

Het uiteindelijke resultaat van dit onderzoek toont aan dat het mogelijk is om een fysieke spelersscore gebruikmakend van machine learning-technieken te berekenen. De gecreëerde modellen hebben echter slechts beperkte voorspellingskracht. De oorzaak hiervoor ligt hoogstwaarschijnlijk aan het feit dat een voetbaluitslag niet louter beslist wordt door de fysieke prestaties van spelers op het veld maar ook aan veel andere factoren, zoals technische statistieken, tactische beslissingen en zelfs weersomstandigheden.

De conclusie van dit onderzoek is dat fysieke prestaties een beperkte invloed hebben op een wedstrijd. Het is echter wel mogelijk om een fysieke score te berekenen met machine learning-technieken en met verder onderzoek is het wellicht mogelijk om een nog betere en objectievere fysieke spelersscore te ontwikkelen.

Inhoudsopgave

Lijst van figuren	viii
Lijst van tabellen	ix
1 Inleiding	1
2 Stand van zaken	3
2.1 Inleiding: Data in het moderne voetbal	3
2.2 Machine learning in het voetbal	4
2.2.1 Wedstrijdanalyse en uitkomstvoorspelling	4
2.2.2 Scouting en spelersranking	4
2.2.3 Trainingsbegeleiding en blessurepreventie	5
2.3 SkillCorner als databron	6
2.3.1 Technologie en werkwijze	6
2.3.2 Fysieke metrieken	6
2.3.3 Toepassing in fysieke scouting	7
2.4 Machine learning	7
2.4.1 Basisconcepten	7
2.4.2 Gesuperviseerd leren: regressie en classificatie	8
2.4.3 Gradient boosting: XGBoost	8
2.4.4 Modelinterpretatie: SHAP-waarden	8
2.4.5 Modelvalidatie	9
2.4.6 Gebruik van grote taalmodellen	9
3 Methodologie	10
3.1 Onderzoeksopzet	10
3.2 Data verzamelen	10
3.3 Data voorbereiding	10
3.4 Feature engineering	11
3.5 Model training	11
3.6 Model evaluatie en vergelijking	11
3.7 Constructie van de fysieke spelersscore	11
3.8 Implementatie in dashboard	12
4 Proof-Of-Concept	13
4.1 Inleiding	13

4.2	Dataverzameling	13
4.2.1	Spelersdata.	13
4.2.2	Wedstrijddata	15
4.3	Data schoonmaken.	15
4.4	Feature engineering	15
4.4.1	Normalisatie per competitie en positie	16
4.4.2	Verschillende datasets	16
4.5	Model training en evaluatie	16
4.5.1	Individuele dataset.	16
4.5.2	Geaggregeerde dataset	17
4.5.3	Verschil-dataset.	18
4.6	Constructie van de fysieke spelersscore	19
4.7	Implementatie in dashboard	19
5	Conclusie	21
5.1	Hoofdonderzoeksvraag	21
5.2	Meerwaarde aan de doelgroep	21
5.3	Toekomstig onderzoek	22
A	Onderzoeksvoorstel	23
A.1	Inleiding	23
A.2	Stand van zaken	24
A.3	Methodologie	26
A.4	Verwacht resultaat, conclusie	26
	Bibliografie	27

Lijst van figuren

4.1	Dashboard spelersfilter	20
4.2	Dashboard uitleg rond score	20

Lijst van tabellen

4.1	Beschrijving van spelersdata	13
4.2	Beschrijving van wedstrijddata	15

1

Inleiding

In het moderne voetbal streven professionele clubs continu naar optimalisatie van prestaties, zowel op als naast het veld. Innovaties in trainingsmethoden, medische begeleiding en data-analyse spelen hierbij een steeds grotere rol. Ook binnen scouting wordt in toenemende mate gebruikgemaakt van data om spelers objectief te evalueren en gerichte beslissingen te ondersteunen.

Binnen deze bachelorproef ligt de focus op het scouten van spelers, meer bepaald op de evaluatie van fysieke prestatie-indicatoren zoals afgelegde afstand per 90 minuten, aantal sprints per 90 minuten en andere wedstrijdgerelateerde fysieke statistieken. Binnen de club die meewerkt aan deze bachelorproef leeft de overtuiging dat fysieke factoren een steeds belangrijkere rol spelen in het moderne voetbal. De huidige evaluatie van deze fysieke aspecten gebeurt echter via een doordachte maar deels subjectieve inschatting door de coaching- en scoutingstaff. Hoewel deze aanpak gebaseerd is op expertise, ontbreekt een reproduceerbare en volledig data-gedreven methode om spelers onderling consistent te vergelijken.

Deze subjectiviteit kan leiden tot inconsistenties in beoordeling en maakt het moeilijk om fysieke prestaties objectief te benchmarken over meerdere wedstrijden of tussen verschillende spelers. Er is daarom nood aan een methode die fysieke prestaties op een gestandaardiseerde en reproduceerbare manier kan kwantificeren.

Door middel van machine learning-technieken zal deze bachelorproef onderzoeken hoe fysieke wedstrijddata kan worden gebruikt om een objectieve fysieke spelersscore te ontwikkelen. Hierbij wordt nagegaan welke fysieke prestatie-indicatoren het meest bijdragen aan de constructie van deze score en hoe hun relatieve belang op een interpreteerbare manier kan worden bepaald.

De centrale onderzoeksvraag van deze bachelorproef luidt als volgt: **Hoe kan een objectieve en reproduceerbare fysieke spelersscore ontwikkeld worden op basis van wedstrijddata met behulp van machine learning-technieken?**

Om deze hoofdvraag systematisch te beantwoorden, is het onderzoek opgesplitst in specifieke **deelvragen**, ingedeeld volgens probleem- en oplossingsdomein:

Probleemdomein

- Welke fysieke spelersattributen worden binnen professioneel voetbal relevant geacht voor prestaties en scouting?
- In welke mate vertonen fysieke spelersstatistieken een verband met wedstrijd-resultaten?
- Welke contextuele factoren (positie, thuis/uit, competitieniveau) beïnvloeden de relevantie van fysieke attributen?

Oplossingsdomein

- Welke machine learning-modellen zijn geschikt voor het voorspellen van wedstrijdresultaten op basis van fysieke data?
- Hoe kunnen explainable machine learning-technieken worden toegepast om de bijdrage van fysieke attributen te interpreteren?
- Hoe kunnen deze inzichten vertaald worden naar praktische toepassingen binnen voetbal scouting?

Het einddoel van deze bachelorproef is deze score objectief te kunnen toepassen in de bestaande data-gedreven scoutingstool van de club, zodat deze een waardevolle aanvulling vormt op de huidige evaluatiemethoden en bijdraagt aan het optimaliseren van het scoutingproces.

De rest van deze bachelorproef is als volgt opgebouwd:

In Hoofdstuk 2 wordt een overzicht gegeven van de stand van zaken binnen het onderzoeksdomein, op basis van een literatuurstudie.

In Hoofdstuk 3 wordt de methodologie toegelicht en worden de gebruikte onderzoekstechnieken besproken om een antwoord te kunnen formuleren op de onderzoeksvragen.

Hoofdstuk 4 licht de uitwerking van het proof of concept toe, van het verzamelen van de data tot het implementeren van de resultaten in de dashboard.

In Hoofdstuk 5, tenslotte, wordt de conclusie gegeven en een antwoord geformuleerd op de onderzoeksvragen. Daarbij wordt ook een aanzet gegeven voor toekomstig onderzoek binnen dit domein.

2

Stand van zaken

2.1. Inleiding: Data in het moderne voetbal

Het professionele voetbal heeft de afgelopen decennia een ware datarevolutie ervaren. Waar coaches en analisten vroeger uitsluitend vertrouwden op visuele observaties en persoonlijke ervaring, beschikken clubs tegenwoordig over enorme hoeveelheden gedetailleerde prestatiedata (Obi et al., [2024](#)). GPS-trackers, optische volgcamera's en draagbare sensoren registreren elke beweging van elke speler gedurende een volledige wedstrijd of training: afgelegde afstand, sprintfrequentie, versnellingen, vertragingen en maximale loopsnelheid behoren tot de standaardoutput van moderne trackingsystemen (De Silva et al., [2018](#)).

Deze datarevolutie wordt mede aangedreven door de commerciële en competitieve druk binnen de topsport. Clubs investeren steeds meer in sportwetenschap en data-analyse om een competitief voordeel te behalen (Houtmeyers et al., [2021](#)). Tegelijkertijd heeft de beschikbaarheid van grootschalige datasets de interesse vanuit de academische wereld gewekt, wat heeft geleid tot een groeiende hoeveelheid aan onderzoek op het snijvlak van machine learning en voetbal (Rico-González et al., [2022](#)).

De hoeveelheid beschikbare data is echter ook een uitdaging op zich. Traditionele statistische methoden schieten tekort wanneer het gaat om het analyseren van complexe, onderling afhankelijke variabelen in een dynamische omgeving zoals voetbal (Davis, Bransen, Devos, Jaspers, Meert, Robberechts, Van Haaren, & Van Roy, [2024](#)). Machine learning biedt een krachtig alternatief: algoritmen die patronen kunnen ontdekken in grote datasets zonder dat elk patroon expliciet geprogrammeerd hoeft te worden. Dit heeft geleid tot een brede toepassing van machine learning in het voetbal, van wedstrijdanalyse en scoutingsondersteuning tot blessurepreventie en fysiek prestatie management.

2.2. Machine learning in het voetbal

2.2.1. Wedstrijdanalyse en uitkomstvoorspelling

Een van de meest onderzochte toepassingen van machine learning in het voetbal is het voorspellen van wedstrijduitkomsten. Verschillende studies hebben aangetoond dat modellen op basis van technische en tactische statistieken, zoals balbezit, schoten op doel en passnauwkeurigheid, een zekere voorspellende waarde hebben voor het wedstrijdresultaat (Mills et al., 2024). Goes et al. (2019) toonden aan dat tactische prestatievariabelen berekend uit positionele trackingdata gebruikt kunnen worden om wedstrijduitkomsten te voorspellen in het professionele Nederlandse voetbal.

Cortez et al. (2021) onderzochten specifiek welke fysiologische en fysieke variabelen het meest bijdragen aan een winnend voetbalteam gebruik makende van een machine learning-aanpak. Hun bevindingen benadrukken dat fysieke prestaties, hoewel niet de enige bepalende factor, een meetbare bijdrage leveren aan wedstrijduitkomsten. Almulla en Alam (2020) bereikten vergelijkbare conclusies in de Qatar Stars League, waarbij machine learning-modellen sleutelprestatievariabelen identificeerden die verband houden met het winnen van wedstrijden. Ook binnen de Belgische context werd dit thema verkend: De Vulder (2024) voerde een vergelijkende analyse uit van verschillende machine learning-modellen voor de voorspelling van wedstrijdslagen bij Club Brugge.

Een belangrijke methodologische uitdaging bij dit type onderzoek is de lage verklarende kracht van modellen die uitsluitend op één type data steunen. Davis, Bransen, Devos, Jaspers, Meert, Robberechts, Van Haaren, en Van Roy (2024) benadrukken dat voetbaluitkomsten worden bepaald door een complexe combinatie van technische, tactische, fysieke en stochastische factoren, waardoor geen enkel model een hoge voorspellingsnauwkeurigheid kan bereiken op basis van slechts één datadimensie. Dit impliceert niet dat zulke modellen waardeloos zijn: zelfs bij lage absolute voorspellingsprestaties kunnen de geleerde gewichten en feature-importances waardevolle inzichten bieden in welke attributen *relatief* het meest bijdragen (Davis, Bransen, Devos, Jaspers, Meert, Robberechts, Van Haaren, & Van Roy, 2024).

2.2.2. Scouting en spelersranking

Naast wedstrijdanalyse heeft machine learning ook een sterke voet aan de grond gekregen in het scouting- en recruitmentproces. Traditioneel verliep scouting bijna uitsluitend via menselijke observatie, wat tijdsintensief, subjectief en kostbaar is (Callinan et al., 2023). Data-gedreven methoden bieden een schaalbaar alternatief dat scouts in staat stelt om grotere spelerspopulaties te evalueren en subjectieve oordelen te verminderen (Vuorenmaa, 2025).

De zogenaamde *Moneyball*-aanpak, oorspronkelijk afkomstig uit het honkbal, heeft

ook in het voetbal ingang gevonden. Liam (2022) analyseerde hoe Brentford FC een statistische benadering adopteerde als competitief voordeel, met opmerkelijk succes voor een club met beperkte financiële middelen. Dit illustreert hoe data-gedreven scouting niet uitsluitend voorbehouden is aan topclubs.

Pappalardo et al. (2018) ontwikkelden PlayeRank, een data-gedreven framework voor het evalueren en ranken van voetballers op basis van event-data. Hun aanpak combineert meerdere prestatievariabelen tot één samengestelde score, rekening houdend met de positie van de speler en het competitieniveau. Dit concept, het omzetten van meerdimensionale prestatiedata naar één vergelijkbare score, vormt ook de basis van het onderzoek in deze thesis, maar dan specifiek toegepast op fysieke trackingdata. Een verwante aanpak werd uitgewerkt door T R et al. (2024), die een scoutingsysteem op basis van verwachte doelpunten (*expected goals*, xG) ontwikkelden met behulp van machine learning.

Yunus en Aditya (2024) benadrukken in hun systematische review dat het standaardiseren van fitnessdata een cruciale stap is voorafgaand aan elke vergelijkende spelersanalyse, aangezien fysieke data sterk variëren tussen competities, clubs en meetmethoden. Dit sluit aan bij de methodologische keuze in deze thesis om fysieke statistieken te standaardiseren per competitie en positiegroep voorafgaande aan verdere analyse.

2.2.3. Trainingsbegeleiding en blessurepreventie

Een derde toepassingsgebied is het optimaliseren van trainingsbelasting en het voorkomen van blessures. Houtmeyers et al. (2021) onderzochten hoe het monitoren van belasting in de praktijk wordt toegepast bij Europese eliteclubs en welke rol clubcultuur en financiële middelen daarin spelen. Hun studie toont aan dat de adoptie van datagedreven trainingsopvolging sterk varieert tussen clubs. Coaches zijn bovendien niet altijd even vertrouwd met data-analyse: Anyadike-Danes et al. (2023) stelden in een internationale bevraging vast dat coachpercepties over trainingsadaptatie sterk uiteenlopen en niet steeds overeenstemmen met wetenschappelijke inzichten.

Mandorino et al. (2023) ontwikkelden een machine learning-aanpak om de spelersgereedheid (*player readiness*) te kwantificeren aan de hand van fysieke trainingsdata. Fernández et al. (2016) onderzochten de relatie tussen trainingsdata en wedstrijdprestaties via voorspellende modellen op basis van trackingdata, en toonden aan dat trainingsintensiteit voorspellende waarde heeft voor individuele wedstrijdprestaties. De Silva et al. (2018) presenteren een gevalstudie van Chelsea FC Academy, waarbij trackingdata worden ingezet als instrument voor fysiek prestatie management op lange termijn.

Campos-Redondo et al. (2025) introduceerden een aanpak voor het opstellen van prestatieprofielen op basis van fysieke trainingsaspecten, en tonen aan dat fysieke profielen een waardevolle aanvulling vormen op technisch-tactische analyses. Calderón-

Díaz et al. (2023) pasten explainbare machine learning-technieken toe om spierblessures bij professionele spelers te voorspellen via biomechanische analyse. Hun gebruik van SHAP-waarden (*SHapley Additive exPlanations*) om modeluitkomsten te interpreteren is methodologisch relevant voor deze thesis, die een vergelijkbare aanpak hanteert om de bijdrage van individuele fysieke attributen zichtbaar te maken.

2.3. SkillCorner als databron

2.3.1. Technologie en werkwijze

De fysieke data die in dit onderzoek worden gebruikt, zijn afkomstig van SkillCorner, een sportdatabedrijf opgericht in 2015 (SkillCorner, 2025). Waar traditionele trackingsystemen afhankelijk zijn van dure vaste camerasinstallaties in elk stadion, onderscheidt SkillCorner zich door trackingdata te extraheren uit bestaand uitzendmateriaal via computer vision en machine learning (SkillCorner, 2024). Dit maakt het mogelijk om spelers te volgen over meer dan 120 competities wereldwijd, zonder dat per stadion een afzonderlijke infrastructuur vereist is.

De technologische pipeline van SkillCorner bestaat uit meerdere opeenvolgende stappen: beeldherkenning om te bepalen of een frame van de hoofdcamera of een herhaling afkomstig is, detectie en classificatie van spelers, scheidsrechters en de bal, homografische schatting om de tweedimensionale beeldcoördinaten om te zetten naar veldcoördinaten, en temporele tracking om detecties van frame tot frame te verbinden. Wanneer spelers buiten beeld zijn, voorspelt een extrapolatiemodel hun meest waarschijnlijke positie, zodat een ononderbroken datasignaal beschikbaar blijft voor de volledige negentig minuten.

2.3.2. Fysieke metriecken

Uit de positionele trackingdata leidt SkillCorner een reeks gestandaardiseerde fysieke metriecken af die toelaten om spelers objectief te vergelijken over competities en seizoenen heen. Enkele metriecken die in dit onderzoek worden gebruikt zijn:

- **Totale afstand en loopafstand:** totale afgelegde afstand en afstand afgelegd boven een bepaalde snelheidsdrempel per wedstrijd.
- **High Speed Running (HSR):** afstand en aantal acties afgelegd tussen 20 en 25 km/u.
- **Sprintafstand en sprintaantal:** afstand en acties boven 25 km/u
- **High Intensity (HI):** combinatie van HSR en sprint, alle acties boven 20 km/u.
- **PSV-99** (*Peak Sprint Velocity 99th percentile*): de 99e percentiel van de maximale snelheid van een speler, als maat voor de herhaaldelijk haalbare topsnelheid

- **Versnellingen en vertragingen:** aantallen matige en hoge versnellingen en vertragingen per wedstrijd.
- **Change of Direction (COD):** het aantal richtingswisselingen uitgevoerd op hoge intensiteit.

Deze metrieken worden in het onderzoek genormaliseerd per negentig minuten speeltijd om vergelijkingen tussen spelers met verschillende speelminuten mogelijk te maken.

2.3.3. Toepassing in fysieke scouting

De brede competitiedekking van SkillCorner maakt de data bijzonder waardevol voor scoutingsdoeleinden. Clubs kunnen via de data de fysieke capaciteiten van spelers in minder bekende competities vergelijken met die van spelers in topcompetities, op basis van gestandaardiseerde metrieken. Dit sluit aan bij de bevindingen van Yunus en Aditya (2024), die standaardisatie van fitnessdata identificeren als een sleutelvoorwaarde voor betrouwbare spelervergelijking.

In het kader van dit project werd door de betrokken club een dashboard ontwikkeld dat de fysieke scores van spelers, berekend via de in deze thesis beschreven methode, visualiseert en doorzoekbaar maakt voor de scoutingstaf. Dit dashboard laat toe om spelers te filteren op positiegroep, competitie en seizoen, en plaatst hun fysieke score in de context van hun leeftijd en speelminuten. Op die manier fungeert de thesis niet enkel als academisch onderzoek, maar levert ze ook een direct inzetbaar instrument op voor het fysieke scoutingproces van de club.

2.4. Machine learning

2.4.1. Basisconcepten

Machine learning is een deelgebied van artificiële intelligentie waarbij algoritmen patronen leren uit data zonder dat het gewenste gedrag expliciet geprogrammeerd wordt (Pietraszewski et al., 2025). In plaats van vaste regels te volgen, optimaliseert een machine learning-model zijn parameters op basis van trainingsvoorbeelden, met als doel zo goed mogelijk te generaliseren naar nieuwe, ongeziene data (Géron, 2023).

Er wordt een fundamenteel onderscheid gemaakt tussen *gesuperviseerd leren* (*supervised learning*) en *ongesuperviseerd leren* (*unsupervised learning*). Bij gesuperviseerd leren worden de trainingsvoorbeelden voorzien van een label of doelwaarde, bijvoorbeeld de uitkomst van een wedstrijd of de eindscore van een speler, en leert het model een afbeelding van invoervariabelen naar die doelwaarde. Bij ongesuperviseerd leren zijn er geen labels beschikbaar en probeert het algoritme zelf structuur te ontdekken in de data, zoals clusters van vergelijkbare spelers of posities (Géron, 2023; Rico-González et al., 2022).

2.4.2. Gesuperviseerd leren: regressie en classificatie

Binnen gesuperviseerd leren wordt verder onderscheid gemaakt tussen *regressie* en *classificatie*. Bij regressie is de doelwaarde continu, zoals het doelpuntenverschil in een wedstrijd. Bij classificatie is de doelwaarde categorisch, zoals het wedstrijdresultaat (winst, gelijkspel of verlies) (Géron, 2023).

Lineaire regressiemodellen, zoals Ridge- en Lasso-regressie, modelleren een lineaire relatie tussen invoervariabelen en de doelwaarde. Ridge-regressie voegt een L2-regularisatieterm toe aan de kostfunctie om overfitting te vermijden, terwijl Lasso-regressie via L1-regularisatie automatisch irrelevante variabelen naar nul duwt en zo impliciete variabeleselectie uitvoert (Géron, 2023). Deze modellen zijn goed interpreteerbaar, de coëfficiënten geven direct de richting en relatieve grootte van het effect van elke variabele aan, maar ze gaan ervan uit dat de relaties in de data lineair en additief zijn, wat in de context van voetbalprestaties zelden het geval is (Almulla & Alam, 2020).

Wanneer de relaties complexer of niet-lineair zijn, bieden boomgebaseerde methoden een krachtig alternatief. *Beslissingsbomen* (*decision trees*) splitsen de data recursief op basis van de meest informatieve variabele op elk knooppunt. *Ensemblemethoden* zoals Random Forests en Gradient Boosted Trees combineren meerdere beslissingsbomen om de variantie te verlagen en de voorspellingsprestaties te verbeteren (Géron, 2023; Mills et al., 2024).

2.4.3. Gradient boosting: XGBoost

XGBoost (*eXtreme Gradient Boosting*) is een bijzonder efficiënte en veelgebruikte implementatie van gradient boosting, ontwikkeld door Chen en Guestrin (2016). Het model bouwt iteratief een ensemble van beslissingsbomen op, waarbij elke nieuwe boom de resterende fouten van het vorige ensemble corrigeert via gradientafdeling in de functieruimte. XGBoost ondersteunt zowel regressie- als classificatietaken en biedt ingebouwde L1- en L2-regularisatie om overfitting te beperken (Chen & Guestrin, 2016).

Een belangrijk voordeel van boomgebaseerde modellen in de context van sportanalyse is hun vermogen om niet-lineaire interacties tussen variabelen op te vangen (Mandorino et al., 2023). De fysieke prestatiekenmerken van een voetballer interageren immers op complexe wijze: een hoge sprintafstand gecombineerd met een hoog aantal versnellingen levert mogelijk meer informatie op dan beide variabelen afzonderlijk. XGBoost werd reeds succesvol toegepast in verschillende voetbalanalysestudies, onder meer voor de voorspelling van wedstrijduitkomsten (Mills et al., 2024) en de kwantificering van spelersgereedheid (Mandorino et al., 2023).

2.4.4. Modelinterpretatie: SHAP-waarden

Een traditioneel nadeel van complexe machine learning-modellen zoals XGBoost is hun beperkte interpreteerbaarheid: het is niet altijd duidelijk *waarom* een model

een bepaalde voorspelling maakt. Om dit probleem aan te pakken, ontwikkelden Lundberg en Lee (2017) de SHAP-methode (*SHapley Additive exPlanations*), een theoretisch gefundeerd kader voor het toewijzen van bijdragen aan individuele variabelen.

SHAP-waarden zijn gebaseerd op het concept van Shapley-waarden uit de speltheorie en meten voor elke variabele hoeveel deze de voorspelling van het model verschuift ten opzichte van de gemiddelde voorspelling (Lundberg & Lee, 2017). Dit levert per observatie én per variabele een concrete bijdragewaarde op, wat het mogelijk maakt om zowel globale als lokale modelverklaringen te genereren. De *TreeExplainer*-implementatie in de SHAP-bibliotheek is specifiek geoptimaliseerd voor boomgebaseerde modellen en berekent exacte Shapley-waarden in polynomiale tijd (Lundberg & Lee, 2017). Calderón-Díaz et al. (2023) pasten deze methode eerder toe in een voetbalcontext om spierblessures te voorspellen en modeluitkomsten interpreteerbaar te maken voor sportprofessionals.

In de context van deze thesis worden SHAP-waarden gebruikt om te bepalen welke fysieke attributen het meest bijdragen aan de classificatie van het wedstrijdresultaat door het XGBoost-model. Door de gemiddelde absolute SHAP-waarden per variabele en per positiegroep te berekenen, worden gewichten verkregen die de relatieve fysieke importantie per positie weerspiegelen.

2.4.5. Modelvalidatie

Een cruciaal aspect van elk machine learning-onderzoek is een correcte validatiemethodologie. Davis, Bransen, Devos, Jaspers, Meert, Robberechts, Van Haaren, en Van Roy (2024) wijzen erop dat onzorgvuldige validatie, zoals het evalueren op trainingsdata of het negeren van temporele afhankelijkheden, leidt tot overschatting van modelprestaties en onbetrouwbare conclusies. *Kruisvalidatie* (*k-fold cross-validation*) is een standaardtechniek waarbij de data herhaaldelijk opgesplitst wordt in trainings- en validatiesets, zodat de gerapporteerde prestaties een betrouwbare schatting geven van de generalisatiecapaciteit van het model (Davis, Bransen, Devos, Jaspers, Meert, Robberechts, Van Haaren, & Van Roy, 2024; Géron, 2023).

Voor het extraheren van stabiele feature-importances past deze thesis een *gestratificeerde kruisvalidatie* toe: het model wordt k keer getraind op verschillende deelssets van de data, waarna de SHAP-importances gemiddeld worden over alle splits. Dit reduceert de variantie in de gewichten en verhoogt de betrouwbaarheid van de uiteindelijke spelersscores.

2.4.6. Gebruik van grote taalmodellen

Bij de ontwikkeling van de code werd gebruik gemaakt van Claude, een groot taalmodel (*large language model*, LLM) ontwikkeld door Anthropic (Anthropic, 2025). Alle methodologische keuzes, validaties en conclusies zijn door de auteur zelf beoordeeld en verantwoord.

3

Methodologie

3.1. Onderzoeksopzet

Het doel van deze bachelorproef is het ontwikkelen van een interpreteerbare en reproduceerbare fysieke spelersscore ter ondersteuning van objectieve voetbal scouting. De realisatie hiervan hanteert een data-gedreven methodologie waarbij machine learning-modellen worden ingezet om het relatieve belang van fysieke prestatie-indicatoren te bepalen.

Er wordt gekozen voor een hybride aanpak waarbij supervised learning gecombineerd wordt met model-interpretatietechnieken. Daarnaast onderzoekt deze studie het belang van de fysieke prestatie-indicatoren per positiegroep, zo worden de fysieke rolvereisten per positie berekend.

3.2. Data verzamelen

Voor het verzamelen van de data wordt gebruikgemaakt van de dataverzamelmethode van KAA Gent. De spelersdataset bestaat uit wedstrijdgerelateerde fysieke prestatie-indicatoren per speler per wedstrijd en het aantal doelpunten van de thuis- en uitploeg in deze wedstrijden, opgehaald uit de Skillcorner data.

3.3. Data voorbereiding

De opgehaalde data bevat nog te veel overbodige elementen:

- irrelevante features (bijvoorbeeld de *afgelegde afstand* in de wedstrijd en *minuten* in de wedstrijd maken *afgelegde afstand per minuut* overbodig)
- features met te weinig data (bijvoorbeeld een feature waar er slechts bij 30% van de spelers een ingevulde waarde is)

- spelers die te weinig minuten in wedstrijden speelden (bijvoorbeeld een speler die slechts 5 minuten speelde gaat een vertekend beeld geven per 90 minuten)

In deze stap worden deze redundante gegevens uit de data verwijderd om met een opgeschoonde dataset naar de volgende stap te kunnen gaan.

3.4. Feature engineering

De kwantitatieve features worden genormaliseerd per 90 minuten om onderlinge vergelijkbaarheid te garanderen. Daarna wordt de data verder gestandaardiseerd per positie (bijvoorbeeld centrale verdedigers, flankverdedigers, centrale middenvelders en flankaanvallers) en competitie, zodat verschillen in fysieke vereisten en spelcontext tussen posities en competities worden meegenomen.

Vervolgens wordt de data per ploeg en per wedstrijd geaggregeerd op basis van het gemiddelde per positie, zodat elke rij overeenkomt met het resultaat van één wedstrijd. Op die manier is de dataset klaar om gebruikt te worden voor het trainen van het machine learning-model.

3.5. Model training

Er werden verschillende modellen en methoden getest, die verder worden besproken in hoofdstuk 4. Deze omvatten regressie-, classificatie- en hybride modellen, telkens met verschillende vormen van inputdata. Het resultaat is een reeks modellen, waarvan het best presterende model wordt geselecteerd voor de berekening van de fysieke score.

3.6. Model evaluatie en vergelijking

De classificatiemodellen worden geëvalueerd op basis van accuraatheid en de F1-score, terwijl de regressiemodellen worden beoordeeld aan de hand van de RMSE (*Root Mean Squared Error*).

3.7. Constructie van de fysieke spelersscore

De essentie van dit onderzoek is het construeren van een fysieke spelersscore. Om het relatieve belang van individuele fysieke variabelen te bepalen, wordt gebruikgemaakt van SHAP (SHapley Additive exPlanations). SHAP-waarden kwantificeren de bijdrage van elke feature aan de voorspelling van het model. Deze bijdragen (of gewichten) worden vervolgens gegroepeerd per positie en omgerekend naar een procentuele bijdrage.

Vervolgens wordt voor elke speler en elke wedstrijd waarin hij minstens een bepaald aantal minuten speelde een score berekend op basis van deze gewichten. Daarna wordt per speler een gewogen gemiddelde berekend over alle wedstrijden

binnen dezelfde competitie en hetzelfde seizoen. Ten slotte worden deze scores geschaald naar een interpreteerbare waarde tussen 0 en 100, wat resulteert in de uiteindelijke fysieke score.

3.8. Implementatie in dashboard

Als laatste stap worden alle spelers en hun scores gevisualiseerd op een extra pagina binnen het bestaande dashboard. Op deze pagina kunnen de spelers en hun fysieke scores worden geraadpleegd, met de mogelijkheid om via filters een selectie van spelers te maken. Daarnaast is er uitleg beschikbaar over de berekening van de scores, evenals een overzicht van de belangrijkste fysieke factoren per positie die bijdragen aan deze scores.

4

Proof-Of-Concept

4.1. Inleiding

In dit hoofdstuk worden alle fasen van de methodologie uitgebreid besproken, van het verzamelen van de data tot de implementatie van de visualisatie van de spelersscore in het dashboard.

4.2. Dataverzameling

De eerste fase bestaat uit het ophalen van data via de SkillCorner API-endpoints. Hieruit verkrijgen we alle informatie die nodig is voor het trainen van het machine learning-model. We halen hiervoor twee datasets op: enerzijds de fysieke spelersstatistieken per speler per wedstrijd uit 25 competities sinds 2023, en anderzijds de wedstrijdresultaten.

4.2.1. Spelersdata

De fysieke data wordt in de oude pipeline reeds opgehaald uit de SkillCorner dataset in de vorm van een JSON-bestand, hier vervangt een functie nog enkele *NaN*-waarden naar *null* voor een succesvolle dataophaling, en ziet er als volgt uit:

Tabel 4.1: Beschrijving van spelersdata

Kolom	Beschrijving
Player_name	Volledige naam van de speler
Player_short_name	Verkorte of gebruikte naam van de speler
Player_id	Unieke identifier van de speler
Player_birthdate	Geboortedatum van de speler
Team_name	Naam van het team

Team_id	Unieke identifier van het team
Match_name	Naam van de wedstrijd
Match_id	Unieke identifier van de wedstrijd
Match_date	Datum van de wedstrijd
Competition_name	Naam van de competitie
Competition_id	Unieke identifier van de competitie
Season_name	Naam van het seizoen
Season_id	Unieke identifier van het seizoen
Competition_edition_id	Identificatie van de competitie-editie
Position	Speelpositie van de speler
Position_group	Gegroepeerde positie (bv. centrale verdediger, flank-speler...)
Minutes_full_all	Gespeelde minuten in de wedstrijd
Physical_check_passed	Indicator of fysieke data geldig is
Total_distance_full_all	Totale afgelegde afstand
Total_metersperminute_full_all	Afgelegde meters per minuut
Running_distance_full_all	Totale afgelegde afstand al lopend
Hsr_distance_full_all	Totale afgelegde afstand aan hoge snelheid
Hsr_count_full_all	Aantal keer gelopen aan hoge snelheid
Sprint_distance_full_all	Sprintafstand
Sprint_count_full_all	Aantal sprints
Hi_distance_full_all	Totale afgelegde afstand aan hoge intensiteit
Hi_count_full_all	Aantal acties aan hoge intensiteit
Psv99	Snelste reproduceerbare snelheid behaald
Medaccel_count_full_all	Aantal middelmatige acceleraties
Highaccel_count_full_all	Aantal hoge acceleraties
Meddecel_count_full_all	Aantal middelmatige deceleraties
Highdecel_count_full_all	Aantal hoge deceleraties
Explacceltohsr_count_full_all	Aantal explosieve acceleraties naar high-speed running
Timetohsr	Tijd tot high-speed running
Timetohsrpostcod	Tijd tot high-speed running na richtingsverandering
Explacceltosprint_count_full_all	Aantal explosieve acceleraties naar sprint
Timetosprint	Tijd tot sprint
Timetosprintpostcod	Tijd tot sprint na richtingsverandering

Cod_count_full_all	Aantal <i>changes of direction</i> (richtingsveranderingen)
Timeto505around90	Tijd voor 5-0-5-test (90° variant)
Timeto505around180	Tijd voor 5-0-5-test (180° variant)

4.2.2. Wedstrijddata

De wedstrijddata wordt nog niet opgehaald, hiervoor dient het *match*-endpoint van SkillCorner. Hieruit halen we onderstaande data van de wedstrijden in de vorm van een JSON-bestand:

Tabel 4.2: Beschrijving van wedstrijddata

Kolom	Beschrijving
Match_id	Unieke identifier van de wedstrijd
Home_team_id	Unieke identifier van de thuisploeg
Home_team	Naam van de thuisploeg
Away_team_id	Unieke identifier van de uitploeg
Away_team	Naam van de uitploeg
Home_goals	Aantal doelpunten gescoord door de thuisploeg
Away_goals	Aantal doelpunten gescoord door de uitploeg

4.3. Data schoonmaken

Na het ophalen van de data volgt de fase van datacleaning. Hierbij worden acht kolommen verwijderd: twee kolommen (*total_metersperminute_full_all* en *physical_check_passed*) vanwege overbodigheid en zes kolommen (*Timetoohsr*, *Timetoohsrpostcod*, *Timetosprint*, *Timetosprintpostcod*, *Timeto505around90*, *Timeto505around180*) vanwege een groot aantal ontbrekende waarden. Daarnaast worden alle spelers die minder dan 75 minuten in de wedstrijd speelden ook verwijderd, evenals alle spelers die hebben deelgenomen aan wedstrijd waarvoor geen wedstrijddata beschikbaar is.

4.4. Feature engineering

Bij het samenbrengen (*mergen*) van beide datasets worden op basis van het team van de speler en de wedstrijd twee nieuwe kolommen gecreëerd: het *matchresultaat* (W, D of L) en het *doelpuntenverschil* (gescoorde doelpunten minus tegen-doelpunten).

Tijdens de feature engineering-fase wordt alle kwantitatieve data omgezet naar relatieve waarden per 90 minuten. De kwalitatieve variabele *psv99* wordt onveranderd behouden. Vervolgens worden alle features genormaliseerd met behulp van

StandardScaler, zodat ze op een vergelijkbare schaal liggen (gemiddelde van 0 en standaardafwijking van 1).

4.4.1. Normalisatie per competitie en positie

Deze schaalverandering wordt uitgevoerd per positie en per competitie. Het afzonderlijk schalen per positie is noodzakelijk omdat verschillende posities inherent andere fysieke eisen hebben; bijvoorbeeld middenvelders leggen doorgaans meer afstand af dan verdedigers, zonder dat dit noodzakelijk een verschil in fysieke kwaliteit impliceert. Door per positie te normaliseren worden deze structurele verschillen geneutraliseerd.

Daarnaast wordt ook per competitie geschaald, aangezien speelstijlen sterk kunnen verschillen tussen competities. Zo staat La Liga traditioneel bekend om meer positiespel en balbezitgericht voetbal, terwijl de Premier League doorgaans een hoger tempo en meer fysieke intensiteit kent. Door deze verschillen te corrigeren, worden competitiegebonden speelstijlverschillen geneutraliseerd, waardoor spelers beter vergelijkbaar worden over competities heen.

4.4.2. Verschillende datasets

Er worden daarnaast verschillende datasets gecreëerd om het model op verschillende manieren te kunnen trainen:

- De individuele dataset: elke speler wordt beschreven door zijn genormaliseerde fysieke statistieken, met het wedstrijdresultaat als targetvariabele.
- De geaggregeerde dataset: per team wordt het gemiddelde berekend van elke fysieke statistiek, per positie.
- De dataset met beide ploegen: de geaggregeerde datasets van beide teams die tegen elkaar speelden worden samengevoegd.
- De verschil-dataset: uit de dataset met beide ploegen worden de verschillen tussen de overeenkomstige features van beide teams berekend.

4.5. Model training en evaluatie

In deze fase worden alle modellen getraind, geëvalueerd en vergeleken. De hyperparameters van alle modellen die beter presteren dan voorgaande modellen worden geoptimaliseerd.

4.5.1. Individuele dataset

PCA

De eerste methode die in dit onderzoek wordt toegepast is een unsupervised learning-techniek, namelijk PCA (*Principal Component Analysis* of *Hoofdcomponentenana-*

lyse). Deze methode reduceert de dimensionaliteit van een dataset door onderliggende verbanden tussen variabelen te identificeren en nieuwe componenten te construeren die lineaire combinaties zijn van de oorspronkelijke variabelen.

De eerste hoofdcomponent verklaart ongeveer 46% van de variantie in de data. Dit is een relatief hoog aandeel voor één component, waardoor het mogelijk is om op basis hiervan een fysieke score te construeren.

Deze aanpak houdt echter geen rekening met het matchresultaat, aangezien PCA volledig unsupervised is. In de context van deze bachelorproef, waar het voorspellen en verklaren van wedstrijdresultaten centraal staat, blijkt deze methode daarom minder geschikt.

Regressiemodellen

Naast PCA wordt ook een regressie-aanpak getest op de individuele dataset, waarbij het doel is om het doelpuntenverschil van een wedstrijd te voorspellen.

Hiervoor wordt XGBoost-regressie gehanteerd. De prestatie van dit model is echter beperkt. De *XGBoost-regressor* behaalt een *RMSE* van ongeveer 1,65, wat wijst op een relatief grote foutmarge in de voorspellingen. Dit blijkt ook uit het feit dat de standaardafwijking van het doelpuntensaldo slechts 1,76 is.

Over het algemeen blijkt dat een regressiemodel minder geschikt is voor deze dataset.

Classificatiemodellen

Een andere aanpak die wordt gehanteerd op de individuele dataset is classificatie, waarbij het doel is om het wedstrijdresultaat (W, D of L) te voorspellen.

Hiervoor worden twee modellen getest: *logistic regression* en *XGBoost-classifier*. Beide modellen behalen een nauwkeurigheid van ongeveer 40%. Dit is beter dan gokken maar nog altijd geen uitstekend resultaat.

Besluit individuele dataset

De individuele modellen tonen geen tevredenstellende resultaten. Dit is grotendeels verklaarbaar door twee redenen:

1. Wanneer enkel naar fysieke prestaties wordt gekeken, is het voorspellen van een matchresultaat moeilijk, aangezien een wedstrijdresultaat van meerdere factoren afhankelijk is.
2. Voetbal is een teamsport; een matchresultaat voorspellen op basis van de prestaties van een individu baseert zich slechts op een klein deel van het geheel.

4.5.2. Geaggregeerde dataset

Classificatiemodellen

Bij de geaggregeerde dataset ligt de focus op classificatiemodellen, met als doelwit wederom het wedstrijdresultaat. Hier wordt gekozen voor twee modellen, *XGBoost-classifier* en *LightGBM*, beide zogenaamde GBDTs (Gradient Boosting Decision Trees).

De resultaten zijn hier beter dan bij de individuele dataset met een nauwkeurigheid van 44%. Dit is een verbetering van 4% ten opzichte van de classificatie van de individuele dataset.

Besluit geaggregeerde dataset

De geaggregeerde dataset geeft betere resultaten dan de individuele dataset, maar een belangrijke factor werd nog niet besproken: een wedstrijd wordt gespeeld tussen twee teams. Om deze reden focust de volgende dataset zich daar op.

4.5.3. Verschil-dataset

Regressiemodellen

Op de verschil-dataset worden de regressiemodellen *RidgeCV*, *LassoCV* en *XGBoost-regressor* getraind.

De resultaten van de regressiemodellen zijn echter slechter dan die van de individuele dataset, waarbij alle modellen een *RMSE* van ongeveer 1,8 behalen. Deze *RMSE* is zelfs slechter dan de standaardafwijking van het doelpuntenverschil en dus geen geschikte methode voor deze voorspellingstaak.

Er zijn eveneens regressiemodellen getraind op het aantal gescoorde en tegendoelpunten met even weinig succes.

Hybride methode

De zwakke resultaten van de regressiemodellen zijn opvallend. Daarom wordt onderzocht of de voorspellingen alsnog bruikbaar zijn voor classificatiedoeleinden.

Bij een diepere inkijk in de voorspelling is het zichtbaar dat de waarden vaak rond de 0 liggen, met nooit waarden hoger dan 1 of lager dan -1. Om toch een verband te onderzoeken, worden de voorspelde waarden geïnterpreteerd als classificaties. Voorspellingen lager dan -0.05 worden beschouwd als een nederlaag (L), waarden hoger dan 0.05 als een overwinning (W) en waarden daartussen als een gelijkspel (D). De uitkomst van dit experiment valt echter ook tegen, met een accuraatheid van 39%.

Classificatiemodellen

Een classificatiemodel wordt eveneens toegepast op de verschil-dataset. Hier is wederom gekozen voor *XGBoost-classifier* met als doelwit de wedstrijdresultaten. Het laatste model dat getraind wordt, geeft een nauwkeurigheid van 36%. Dit model presteert het slechtst van alle getrainde classificatiemodellen.

Besluit verschil-dataset

De modellen getraind op de verschil-dataset geven de slechtste resultaten van alle getrainde modellen. Vier mogelijke redenen hiervoor zijn:

1. Het nemen van verschillen zorgt voor verlies van informatie, aangezien alle statistieken relatief worden ten opzichte van de tegenstander.

2. Voetbalresultaten zijn niet uitsluitend afhankelijk van fysieke verschillen. Factoren zoals tactiek en individuele kwaliteit hebben eveneens een grote invloed.
3. De structuur en identiteit van teams verdwijnen gedeeltelijk bij het berekenen van verschillen tussen beide ploegen.
4. Het nemen van verschillen kan extra ruis introduceren in de dataset.

4.6. Constructie van de fysieke spelersscore

Na het trainen en evalueren van alle modellen is gekozen voor *XGBoost-classifier* toegepast op de geaggregeerde dataset. De SHAP *TreeExplainer* verklaart de output van het model en haalt zo de *feature contributions* van iedere feature op. Deze bijdragen worden gegroepeerd per positie en de procentuele aandeel ervan wordt binnen de positie wordt berekend met de formule:

$$\frac{w_{i,p}}{\sum_{j \in p} w_{j,p}}$$

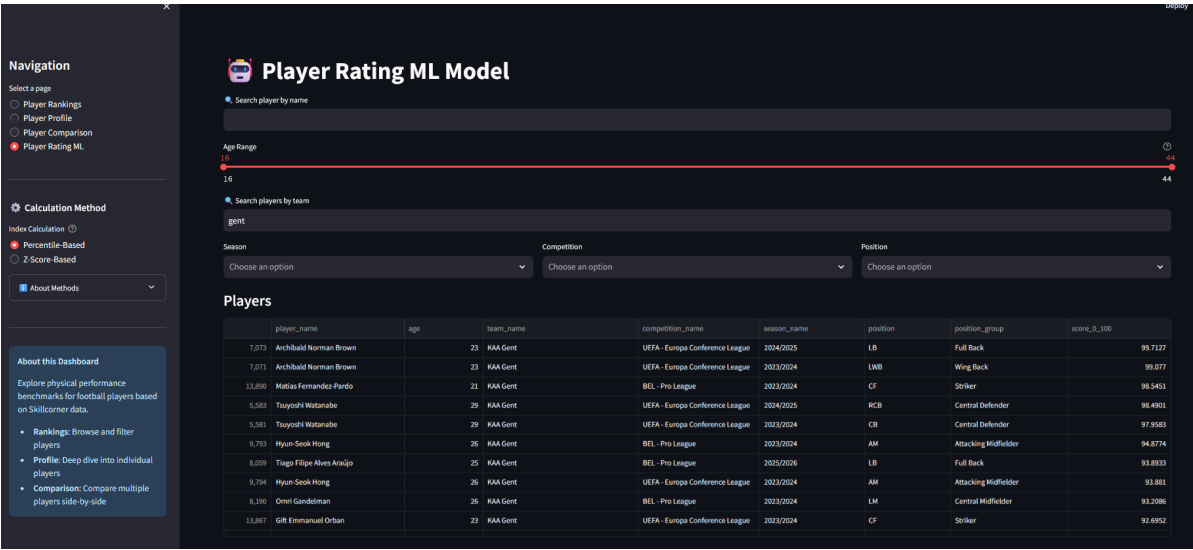
waarbij $w_{i,p}$ het gewicht van een factor van speler i binnen positie p is en de noemer de som van alle gewichten binnen dezelfde positie.

Met deze gewichten wordt dan per wedstrijd een score berekend door ze te vermenigvuldigen met de genormaliseerde overeenkomende fysieke waarden (afhankelijk van de gespeelde positie in die wedstrijd). Hierna wordt een gewogen gemiddelde berekend, gebaseerd op het aantal gespeelde minuten in de wedstrijd, van iedere speler per competitie en seizoen. Zo krijgt iedere speler die voldoet aan de voorwaarden (bijvoorbeeld een minimum aantal wedstrijden) een score over een competitie en seizoen heen. Deze scores worden dan omgezet naar een waarde tussen 0 en 100 waar de hoogste score een 100 wordt en de laagste een 0.

4.7. Implementatie in dashboard

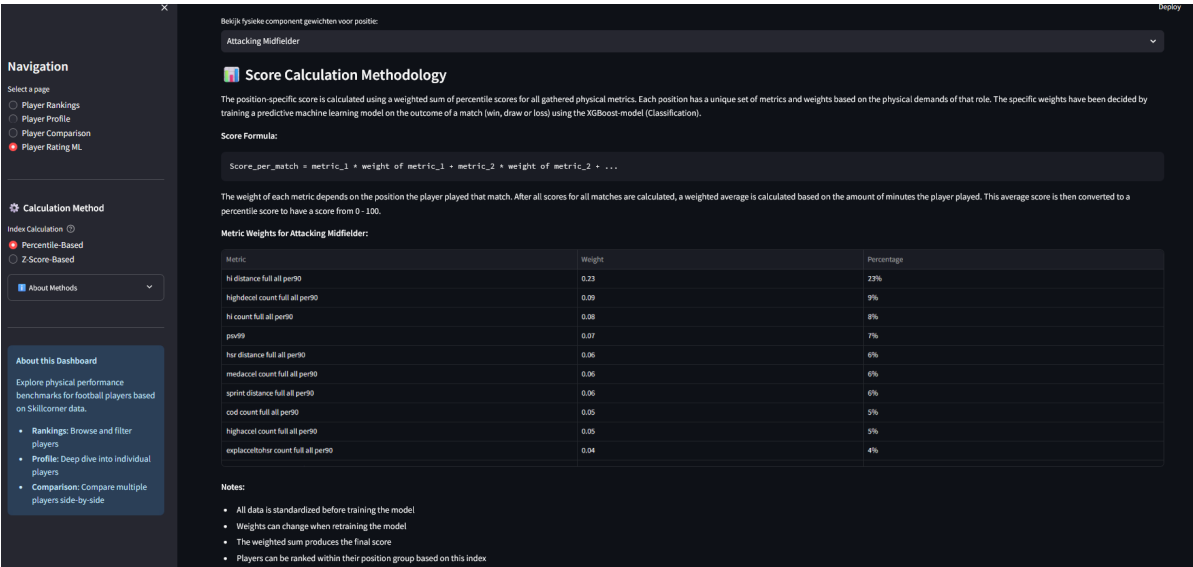
De laatste fase van het onderzoek is de visualisatie van de fysieke spelerscores in het bestaande dashboard. Het dashboard maakt gebruik van Streamlit om alle data te visualiseren. Om deze data efficiënt te verwerken en niet telkens de modellen te moeten hertrainen worden de spelers met alle scores en andere info opgeslagen in een CSV-bestand en worden de gewichten per positie opgeslagen in een pickle-bestand. Deze bestanden worden ingeladen in de nieuwe pagina op het dashboard, dat bestaat uit twee delen, het eerste deel toont de spelers en hun scores en geeft de gebruiker de mogelijkheid om te filteren op naam, leeftijd, team, seizoen, competitie en positie.

Figuur 4.1: Dashboard spelersfilter



Het andere deel van de pagina bestaat uit uitleg over het berekenen van de score alsook toont het een overzicht van de gewichten per positie.

Figuur 4.2: Dashboard uitleg rond score



5

Conclusie

5.1. Hoofdonderzoeksvraag

De hoofdonderzoeksvraag "Hoe kan een objectieve en reproduceerbare fysieke spelersscore ontwikkeld worden op basis van wedstrijddata met behulp van machine learning-technieken?", kan als volgt beantwoord worden. Het is mogelijk om een objectieve en reproduceerbare fysieke spelersscore te ontwikkelen op basis van machine learning-technieken. De score wordt berekend op basis van SHAP-waarden afkomstig uit een XGBoost-classificatiemodel, waardoor de bijdrage van iedere feature op een interpreteerbare manier wordt berekend. De voorspellende prestaties van de onderzochte modellen blijven echter beperkt. Het best presterende model, *XGBoost-classifier* op de geaggregeerde dataset, behaalde een nauwkeurigheid van 44%. Dit ligt hoger dan de willekeurige baseline van 33% in een drieklassenprobleem, maar blijft te laag om te kunnen spreken van een sterk voorspellend model. Dit verhoogde percentage toont echter wel aan dat er een, al dan niet licht, verband is tussen de fysieke prestaties van een team en de wedstrijduitslag.

Hieruit kan worden besloten dat louter fysieke prestatiegegevens slechts een beperkte voorspellende waarde hebben voor het bepalen van wedstrijdresultaten. De belangrijkste bijdrage van dit onderzoek ligt dan niet in het optimaliseren van de modellen, maar in het maken van een interpreteerbare en reproduceerbare fysieke spelersscore.

5.2. Meerwaarde aan de doelgroep

Deze studie draagt bij aan het onderzoeksdomein van data-analyse in de sport door het onderzoek naar het belang van fysieke prestaties, gebruikmakend van machine learning-technieken, bij het behalen van wedstrijdresultaten.

Het biedt een reproduceerbare en objectieve manier om spelers fysiek te evalueren op basis van fysieke wedstrijddata. Hierdoor kunnen data-analisten en scouts

deze aanpak gebruiken als extra ondersteuning naar het zoeken van spelers met interessante fysieke profielen.


Wanneer de gevonden resultaten worden vergeleken met de door mensen ingeschatte gewichten, is zichtbaar dat sommige attributen die door mensen als belangrijk worden beschouwd ook door de machine learning-methode als belangrijk worden geïdentificeerd. Echter zijn er ook attributen waarvoor duidelijke verschillen optreden.

Dit suggereert dat menselijke en machine learning-gebaseerde inschattingen van het belang van bepaalde statistieken niet volledig overeenkomen, wat een aanvullend perspectief kan bieden op de interpretatie van de data.

5.3. Toekomstig onderzoek

Tijdens dit onderzoek zijn er veel mogelijkheden voor alternatief onderzoek naar voren gekomen, waarvan de volgende vier centraal staan:

- Wat is het belang van de *peak-metrics*, zoals de maximale sprintsnelheid, tijd tot sprinten, aantal explosieve versnellingen...
- Eerder onderzoek toont aan dat een clusteringmodel *spelerstypes* kan vinden, maar kunnen er *elite* spelers gevonden worden in deze *spelerstypes*?
- Voortbouwende op het voorgaande, wat is het effect van meerdere *elite* spelers hebben in een wedstrijd?
- Wat is het effect wanneer alle wedstrijdstatistieken (inclusief niet-fysieke variabelen) worden meegenomen in het machine learning-model? Wat is dan de bijdrage van de fysieke statistieken?



Onderzoeksvoorstel

Het onderwerp van deze bachelorproef is gebaseerd op een onderzoeksvoorstel dat vooraf werd beoordeeld door de promotor. Dat voorstel is opgenomen in deze bijlage.

A.1. Inleiding

Professionele voetbalclubs streven voortdurend naar sportieve en competitieve vooruitgang. In dit streven wordt steeds vaker gebruikgemaakt van data en technologie om spelersprestaties te monitoren, te evalueren en te optimaliseren. Door het gebruik van GPS-systemen, wearables en geavanceerde wedstrijdstatistieken beschikken clubs vandaag over een grote hoeveelheid objectieve fysieke prestatiegegevens.

Deze bachelorproef focust zich op het analyseren van fysieke spelersattributen binnen een wedstrijdcontext en onderzoekt hoe machine learning kan bijdragen aan het identificeren van fysiek relevante spelersprofielen. Door fysieke prestatiedata te koppelen aan wedstrijdresultaten wordt nagegaan welke fysieke kenmerken statistisch samenhangen met sportief succes. De doelgroep van dit onderzoek bestaat uit performance analisten en scouts binnen het professionele voetbal die nood hebben aan objectieve, interpreteerbare en data-gedreven ondersteuning bij scouting-beslissingen.

De centrale onderzoeksvraag van deze bachelorproef luidt: **In welke mate kunnen fysieke spelersstatistieken, geanalyseerd met explainable machine learning technieken, bijdragen aan het identificeren van relevante spelersprofielen voor voetbal scouting?**

Het doel van dit onderzoek is het ontwikkelen van een proof-of-concept dat aan toont hoe machine learning en explainable AI kunnen worden ingezet om fysieke

prestatiedata te vertalen naar bruikbare inzichten voor scouting.

Enkele deelvragen met betrekking tot het probleemdomein zijn:

- Welke fysieke spelersattributen worden binnen professioneel voetbal relevant geacht voor prestaties en scouting?
- In welke mate vertonen fysieke spelersstatistieken een verband met wedstrijdresultaten?
- Welke contextuele factoren (positie, thuis/uit, competitieniveau) beïnvloeden de relevantie van fysieke attributen?

Enkele deelvragen met betrekking tot het oplossingsdomein zijn:

- Welke machine learning modellen zijn geschikt voor het voorspellen van wedstrijdresultaten op basis van fysieke data?
- Hoe kunnen explainable machine learning technieken worden toegepast om de bijdrage van fysieke attributen te interpreteren?
- Hoe kunnen deze inzichten vertaald worden naar praktische toepassingen binnen voetbal scouting?

A.2. Stand van zaken

De toepassing van data-analyse en machine learning binnen de sportwereld is de afgelopen jaren sterk toegenomen. In het bijzonder binnen professioneel voetbal worden steeds grotere hoeveelheden data verzameld, gaande van wedstrijd- en eventdata tot gedetailleerde fysieke prestatiedata afkomstig van GPS-systemen en wearables. Deze evolutie heeft geleid tot een groeiend onderzoeksdomein waarin machine learning technieken worden ingezet om sportprestaties te analyseren en te voorspellen.

Een recente systematische review van Pietraszewski et al. (2025) toont aan dat artificial intelligence en machine learning een steeds prominentere rol spelen binnen sport analytics. Volgens de auteurs worden deze technieken voornamelijk ingezet voor prestatie-evaluatie, wedstrijdvoorspelling en blessurepreventie. Hoewel het merendeel van de studies focust op technische en tactische indicatoren, benadrukt de review dat ook fysieke prestatiedata steeds vaker wordt opgenomen in voorspellende modellen. Dit onderstreept het potentieel van machine learning voor het analyseren van fysieke spelersattributen.

Binnen voetbalcontext wordt machine learning voornamelijk toegepast op wedstrijd- en eventdata. Pappalardo et al. (2018) introduceren met het PlayeRank-framework een data-gedreven methode om spelersprestaties te evalueren en te rangschikken. Hoewel dit framework voornamelijk technische en tactische statistieken gebruikt, illustreert het onderzoek hoe machine learning kan worden ingezet om multidimensionale spelersdata te vertalen naar objectieve evaluaties. Deze aanpak vormt

een belangrijke inspiratie voor het toepassen van data-gedreven methoden binnen scoutingprocessen.

Naast technische statistieken is er toenemende aandacht voor het gebruik van fysieke prestatiedata binnen machine learning modellen. Mandorino et al. (2023) tonen aan dat fysieke parameters zoals acceleraties, afstanden en intensieve acties succesvol kunnen worden geïntegreerd in machine learning modellen om de fysieke paraatheid van voetballers te kwantificeren. Dit bevestigt dat fysieke spelersstatistieken niet enkel relevant zijn voor load monitoring, maar ook waardevolle input vormen voor analytische modellen.

Machine learning wordt ook frequent ingezet voor het voorspellen van wedstrijdresultaten. In een studie binnen het *Journal of Big Data* tonen Mills et al. (2024) aan dat zowel klassieke machine learning modellen als meer geavanceerde technieken in staat zijn om voetbalwedstrijden te classificeren op basis van wedstrijdgerelateerde features. Hoewel fysieke statistieken in deze studie niet centraal staan, bevestigt het onderzoek dat match outcome prediction een geschikt kader vormt om de impact van specifieke featuregroepen, zoals fysieke teamkenmerken, te analyseren.

Een belangrijk aandachtspunt binnen sport analytics is de interpreteerbaarheid van machine learning modellen. In professionele omgevingen, zoals voetbal scouting, is het essentieel dat beslissingen niet enkel gebaseerd zijn op voorspellende prestaties, maar ook begrijpelijk en verantwoordbaar zijn. Calderón-Díaz et al. (2023) tonen aan dat explainable machine learning technieken, zoals feature importance en SHAP-waarden, inzicht kunnen bieden in de bijdrage van individuele fysieke kenmerken aan modelvoorspellingen. Hoewel hun onderzoek gericht is op blessurepredictie, is de gebruikte methodologie rechtstreeks toepasbaar op prestatie- en scoutinganalyses.

Tot slot benadrukken methodologische studies het belang van correcte dataverwerking en feature engineering binnen sport analytics. Davis, Bransen, Devos, Jaspers, Meert, Robberechts, Haaren, en Roy (2024) bespreken verschillende uitdagingen met betrekking tot datakwaliteit, aggregatie en evaluatie van machine learning modellen in sportcontexten. Deze uitdagingen zijn bijzonder relevant wanneer fysieke spelersdata wordt geaggregeerd naar teamniveau, zoals vereist is binnen wedstrijdanalyse en scoutinggerichte toepassingen.

Samenvattend toont de literatuur aan dat machine learning een waardevol instrument is binnen sport analytics, maar dat de toepassing van fysieke prestatiedata binnen scouting nog beperkt onderzocht is. Daarnaast blijkt interpreteerbaarheid een cruciale factor voor praktische toepasbaarheid. Deze bachelorproef sluit aan bij deze vaststellingen door fysieke spelersattributen centraal te stellen en explainable machine learning technieken toe te passen binnen een scoutingcontext.

A.3. Methodologie

Het onderzoek wordt uitgevoerd volgens een gestructureerde data science aanpak en bestaat uit meerdere fasen.

In een eerste fase wordt via literatuurstudie onderzocht welke fysieke spelersattributen relevant zijn binnen professioneel voetbal en hoe machine learning reeds wordt toegepast binnen sport analytics. Op basis hiervan wordt een selectie gemaakt van fysieke prestatie-indicatoren.

In de tweede fase wordt een dataset samengesteld bestaande uit wedstrijdgegevens, fysieke spelersstatistieken en wedstrijdresultaten over meerdere seizoenen. Individuele spelersstatistieken worden via feature engineering geaggregeerd naar teamniveau, rekening houdend met positie en speelminuten.

Vervolgens worden verschillende classificatiemodellen ontwikkeld om wedstrijdresultaten (winst, gelijkspel, verlies) te voorspellen op basis van deze fysieke team-features. Hierbij wordt gestart met een interpreteerbaar basismodel, gevolgd door complexere machine learning modellen.

In de laatste fase worden explainable machine learning technieken toegepast om de bijdrage van fysieke attributen aan de modelvoorspellingen te analyseren. De verkregen inzichten worden geïnterpreteerd in functie van voetbal scouting en vertaald naar concrete aanbevelingen.

A.4. Verwacht resultaat, conclusie

Er wordt verwacht dat dit onderzoek aantoont dat bepaalde fysieke spelersattributen een significante bijdrage leveren aan wedstrijdresultaten en dat deze attributen op een objectieve manier kunnen worden geïdentificeerd met behulp van machine learning. Daarnaast wordt verwacht dat explainable AI technieken toelaten om deze resultaten op een transparante en interpreteerbare manier te communiceren.

De bachelorproef zal aantonen dat fysieke prestatiedata niet enkel waardevol is voor trainingsopvolging, maar ook een relevante rol kan spelen binnen voetbal scouting. Het ontwikkelde proof-of-concept biedt een eerste stap richting data-gedreven scoutingbeslissingen waarbij objectieve fysieke profielen worden gecombineerd met menselijke expertise.

Bibliografie

- Almulla, J., & Alam, T. (2020). Machine Learning Models Reveal Key Performance Metrics of Football Players to Win Matches in Qatar Stars League. *IEEE Access*, 8, 213695–213705. <https://doi.org/10.1109/access.2020.3038601>
- Anthropic. (2025). *Claude (claude-sonnet-4-5)* [Large language model, geraadpleegd tijdens het schrijven van deze thesis]. <https://claude.ai>
- Anyadike-Danes, K., Donath, L., & Kiely, J. (2023, 8 september). *Coaches' perceptions of factors driving training adaptation: An international survey*. Geraadpleegd op 12 november 2025, van <https://doi.org/10.1007/s40279-023-01894-1>
- Calderón-Díaz, M., Aguirre, R. S., Váscquez, J. P., Yáñez, R., Roby, M., Querales, M., & Salas, R. (2023). Explainable Machine Learning Techniques to Predict Muscle Injuries in Professional Soccer Players through Biomechanical Analysis. *Sensors*, 24(1), 119. <https://doi.org/10.3390/s24010119>
- Callinan, M. J., Connor, J. D., Sinclair, W. H., & Leicht, A. S. (2023, 24 januari). *Exploring rugby coaches' perception and implementation of performance analytics*. Geraadpleegd op 12 november 2025, van <https://doi.org/10.1371/journal.pone.0280799>
- Campos-Redondo, A., Martínez-Sánchez, A., López-Sierra, P., Chacón-Fernández, E., & García-Rubio, J. (2025). Performance Profiles: A New Approach Based on Training Focused on Physical Aspects Rather than Technical-Tactical Ones. *Sports*, 13(11), 402. <https://doi.org/10.3390/sports13110402>
- Chen, T., & Guestrin, C. (2016). XGBOOST: a scalable tree boosting System. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1603.02754>
- Cortez, A., Trigo, A., & Loureiro, N. (2021, 1 januari). *Predicting Physiological Variables of Players that Make a Winning Football Team: A Machine Learning Approach*. https://doi.org/10.1007/978-3-030-86970-0_1
- Davis, J., Bransen, L., Devos, L., Jaspers, A., Meert, W., Robberechts, P., Haaren, J. V., & Roy, M. V. (2024). Methodology and evaluation in sports analytics: challenges, approaches, and lessons learned. *Machine Learning*. <https://doi.org/10.1007/s10994-024-06585-0>
- Davis, J., Bransen, L., Devos, L., Jaspers, A., Meert, W., Robberechts, P., Van Haaren, J., & Van Roy, M. (2024). Methodology and evaluation in sports analytics: challenges, approaches, and lessons learned. *Machine Learning*, 113(9), 6977–7010. <https://doi.org/10.1007/s10994-024-06585-0>

- De Silva, V., Caine, M., Skinner, J., Dogan, S., Kondo, A., Peter, T., Axtell, E., Birnie, M., & Smith, B. (2018). Player Tracking Data Analytics as a Tool for Physical Performance Management in Football: A Case Study from Chelsea Football Club Academy. *Sports*, 6(4), 130. <https://doi.org/10.3390/sports6040130>
- De Vulder, R. (2024). *Voorspelling van wedstrijduitslagen voor Club Brugge met Machine Learning: Een vergelijkende analyse van verschillende modellen* [Dissertation]. Hogeschool Gent, DIT Departement IT en Digitale Innovatie.
- Fernández, J., Medina, D., Gómez-Díaz, A., Arias, M., & Cevaldà, R. (2016). From Training to Match Performance: A Predictive and Explanatory Study on Novel Tracking Data, 136–143. <https://doi.org/10.1109/ICDMW.2016.0027>
- Géron, A. (2023). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (Third edition, Deel null). O'Reilly Media. <https://research.ebsco.com/plink/a4c0b868-a72d-3943-979e-8349307bc64e>
- Goes, F., Kempe, M., & Lemmink, K. (2019). Predicting match outcome in professional Dutch football using tactical performance metrics computed from position tracking data. *EasyChair preprint*. <https://doi.org/10.29007/4jjb>
- Houtmeyers, K. C., Vanrenterghem, J., Jaspers, A., Ruf, L., Brink, M. S., & Helsen, W. F. (2021, 20 mei). *Load monitoring practice in European elite football and the impact of club culture and financial resources*. Geraadpleegd op 12 november 2025, van <https://doi.org/10.3389/fspor.2021.679824>
- Liam, C. D. (2022, 20 september). *Is the Moneyball approach is a feasible approach for success in Football (Soccer)? An analysis of Brentford's adoption of a statistical approach*. <https://norma.ncirl.ie/id/eprint/5774>
- Lundberg, S., & Lee, S. (2017). A Unified Approach to Interpreting Model Predictions. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1705.07874>
- Mandorino, M., Tessitore, A., Leduc, C., Persichetti, V., Morabito, M., & Lacome, M. (2023). A New Approach to Quantify Soccer Players' Readiness through Machine Learning Techniques. *Applied Sciences*, 13(15), 8808. <https://doi.org/10.3390/app13158808>
- Mills, E. F. E. A., Deng, Z., Zhong, Z., & Li, J. (2024). Data-driven prediction of soccer outcomes using enhanced machine and deep learning techniques. *Journal Of Big Data*, 11(1). <https://doi.org/10.1186/s40537-024-01008-2>
- Obi, N. O. C., Dawodu, N. S. O., Onwusinkwue, N. S., Osasona, N. F., Atadoga, N. A., & Daraojimba, N. A. I. (2024, 27 januari). *Data science in sports analytics: A review of performance optimization and fan engagement*. Geraadpleegd op 12 november 2025, van <https://doi.org/10.30574/wjarr.2024.21.1.0370>
- Pappalardo, L., Cintia, P., Ferragina, P., Massucco, E., Pedreschi, D., & Giannotti, F. (2018). PlayeRank: data-driven performance evaluation and player ranking in soccer via a machine learning approach. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1802.04987>

- Pietraszewski, P., Terbalyan, A., Roczniok, R., Maszczyk, A., Ornowski, K., Manilewska, D., Kuliś, S., Zając, A., & Gołaś, A. (2025). The Role of Artificial Intelligence in Sports Analytics: A Systematic Review and Meta-Analysis of Performance Trends. *Applied Sciences*, 15(13), 7254. <https://doi.org/10.3390/app15137254>
- Rico-González, M., Pino-Ortega, J., Méndez, A., Clemente, F., & Baca, A. (2022). Machine learning application in soccer: a systematic review. *Biology of Sport*, 40(1), 249–263. <https://doi.org/10.5114/biolsport.2023.112970>
- SkillCorner. (2024). *SkillCorner Open Data*. Geraadpleegd op 12 november 2025, van <https://github.com/SkillCorner/opendata>
- SkillCorner. (2025). *Football Analytics Platform*. Geraadpleegd op 12 november 2025, van <https://skillcorner.com/sports/football>
- T R, P., Abhinav, B., Nandan, A., Gurikar, Adithya, Pandharkar, A., & Akshit. (2024). An xG Based Football Scouting System Using Machine Learning Techniques. <https://doi.org/10.1109/I2CT61223.2024.10544261>
- Vuorenmaa, H. (2025). *Artificial Intelligence Supporting Scouts and Sport Clubs in Player Recruitment*. <https://www.theseus.fi/handle/10024/893642>
- Yunus, M., & Aditya, R. S. (2024). Talent scouting and standardizing fitness data in football club: systematic review. *Retos*, 60, 1382–1389. <https://doi.org/10.47197/retos.v60.107767>