

Een machine learning benadering voor het identificeren van relevante fysieke spelersattributen in voetbal scouting.

In samenwerking met KAA Gent.

Vanacker Matthijs.

Scriptie voorgedragen tot het bekomen van de graad van
Professionele bachelor in de toegepaste informatica

Promotor: Dhr. T. Antjon

Co-promotor: Dhr. A. Martiny

Academiejaar: 2025–2026

Eerste examenperiode

Departement IT en Digitale Innovatie .

**HO
GENT**

Woord vooraf

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Samenvatting

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Inhoudsopgave

Lijst van figuren	vi
Lijst van tabellen	vii
Lijst van codefragmenten	viii
1 Inleiding	1
2 Stand van zaken	3
2.1 Inleiding	3
2.2 Machine learning in voetbalanalyse	3
2.3 Datagedreven scouting en spelersrekrutering	4
2.4 Fysieke prestaties als voorspellende factor	4
2.5 Voorspellende modellen voor prestaties en wedstrijden	5
2.6 Geavanceerde scoutingsystemen	5
2.7 Conclusie van de literatuur	5
3 Methodologie	7
3.1 Onderzoekopzet	7
3.2 Dataset en variabelen	7
3.3 Positie-specifieke modellering	7
3.4 Supervised learning	8
3.5 Modelinterpretatie via SHAP	8
3.6 Constructie van de fysieke spelersscore	8
3.7 Validatie van de score	8
4 Conclusie	10
A Onderzoeksvoorstel	12
A.1 Inleiding	12
A.2 Stand van zaken	13
A.3 Methodologie	15
A.4 Verwacht resultaat, conclusie	15
Bibliografie	16

Lijst van figuren

Lijst van tabellen

Lijst van codefragmenten

1

Inleiding

In het moderne voetbal streven professionele clubs continu naar optimalisatie van prestaties, zowel op als naast het veld. Innovaties in trainingsmethoden, medische begeleiding en data-analyse spelen hierbij een steeds grotere rol. Ook binnen scouting wordt in toenemende mate gebruikgemaakt van data om spelers objectief te evalueren en gerichte beslissingen te ondersteunen.

Binnen deze bachelorproef ligt de focus op het scouten van spelers, meer bepaald op de evaluatie van fysieke prestatie-indicatoren zoals afgelegde afstand per 90 minuten, aantal sprints per 90 minuten en andere wedstrijdgerelateerde fysieke statistieken. Binnen de club die meewerkt aan deze bachelorproef leeft de overtuiging dat fysieke factoren een steeds belangrijkere rol spelen in het moderne voetbal. De huidige evaluatie van deze fysieke aspecten gebeurt echter via een doordachte maar deels subjectieve inschatting door de coaching- en scoutingstaff. Hoewel deze aanpak gebaseerd is op expertise, ontbreekt een reproduceerbare en volledig data-gedreven methode om spelers onderling consistent te vergelijken.

Deze subjectiviteit kan leiden tot inconsistenties in beoordeling en maakt het moeilijk om fysieke prestaties objectief te benchmarken over meerdere wedstrijden of tussen verschillende spelers. Er is daarom nood aan een methode die fysieke prestaties op een gestandaardiseerde en reproduceerbare manier kan kwantificeren.

Door middel van machine learning-technieken zal deze bachelorproef onderzoeken hoe fysieke wedstrijddata kan worden gebruikt om een objectieve fysieke spelersscore te ontwikkelen. Hierbij wordt nagegaan welke fysieke prestatie-indicatoren het meest bijdragen aan de constructie van deze score en hoe hun relatieve belang op een interpreteerbare manier kan worden bepaald.

De centrale onderzoeksvraag van deze bachelorproef luidt als volgt: **Hoe kan een objectieve en reproduceerbare fysieke spelersscore ontwikkeld worden op basis van wedstrijddata met behulp van machine learning-technieken?**

Het einddoel van deze bachelorproef is deze score objectief te kunnen toepassen

in de bestaande data-gedreven scoutingstool van de club, zodat deze een waardevolle aanvulling vormt op de huidige evaluatiemethoden en bijdraagt aan het optimaliseren van het scoutingproces.

De rest van deze bachelorproef is als volgt opgebouwd:

In Hoofdstuk 2 wordt een overzicht gegeven van de stand van zaken binnen het onderzoeksdomein, op basis van een literatuurstudie.

In Hoofdstuk 3 wordt de methodologie toegelicht en worden de gebruikte onderzoekstechnieken besproken om een antwoord te kunnen formuleren op de onderzoeksvragen.

In Hoofdstuk 4, tenslotte, wordt de conclusie gegeven en een antwoord geformuleerd op de onderzoeksvragen. Daarbij wordt ook een aanzet gegeven voor toekomstig onderzoek binnen dit domein.

2

Stand van zaken

2.1. Inleiding

De digitalisering van het moderne voetbal heeft geleid tot een sterke toename in beschikbare data over spelers en wedstrijden. Professionele clubs maken gebruik van geavanceerde analysetechnieken om prestaties te evalueren, blessures te voorkomen en gerichter spelers te rekruteren. In deze context speelt artificiële intelligentie (AI) een steeds grotere rol. AI verwijst naar computersystemen die taken uitvoeren waarvoor normaal menselijke intelligentie vereist is, zoals patroonherkenning en besluitvorming. Een belangrijk onderdeel hiervan is *machine learning* (ML), waarbij algoritmen automatisch patronen leren uit historische data om voorspellingen te doen.

Binnen scouting — het proces waarbij spelers worden geëvalueerd en geselecteerd — biedt ML mogelijkheden om objectiever en consistent talent te identificeren. Verschillende studies onderzochten reeds hoe datagedreven technieken kunnen bijdragen aan spelersanalyse, prestatievoorspelling en talentdetectie.

2.2. Machine learning in voetbalanalyse

Een uitgebreide overzichtsstudie van Rico-González et al., [2022](#) toont aan dat ML in voetbal hoofdzakelijk wordt toegepast in drie domeinen: blessurevoorspelling, prestatieanalyse en talentidentificatie. Vooral in prestatieanalyse worden voorspellende modellen gebruikt om wedstrijdresultaten, fysieke belasting en technische acties te analyseren. De auteurs benadrukken dat ML-modellen sterk afhankelijk zijn van voldoende grote datasets, wat essentieel is voor betrouwbare voorspellingen.

Ook Yunus en Aditya, [2024](#) bevestigen via een systematische literatuurstudie dat datagedreven scouting steeds belangrijker wordt. Zij benadrukken specifiek het belang van het standaardiseren van fysieke meetgegevens, zodat spelers objectief

kunnen worden vergeleken. Dit is cruciaal omdat subjectieve beoordelingen van scouts kunnen leiden tot inconsistente evaluaties.

2.3. Datagedreven scouting en spelersrekrutering

Volgens Vuorenmaa, 2025 helpt AI sportclubs bij het objectiveren van rekruteringsprocessen. Traditionele scouting steunt sterk op observaties en intuïtie van experts, terwijl AI-systemen grote hoeveelheden spelersdata kunnen analyseren om verbor-gen patronen te detecteren. Hierdoor kunnen clubs efficiënter spelers identificeren die passen binnen hun speelstijl en budget.

Een concreet voorbeeld hiervan is het werk van Ghar et al., 2021, waarin een datagedreven scoutingsysteem wordt voorgesteld dat toekomstige spelersprestaties simuleert. Simulatie betekent hier dat een model voorspelt hoe een speler zou presteren in andere omstandigheden, bijvoorbeeld in een andere competitie of ploeg. Deze aanpak helpt clubs om transferbeslissingen beter te onderbouwen.

De studie van Liam, 2022 bespreekt de zogenaamde “Moneyball”-benadering in voetbal, waarbij statistische analyse centraal staat bij spelersselectie. Clubs zoals Brentford FC tonen aan dat een systematische, cijfermatige aanpak kan leiden tot competitief voordeel tegenover financieel sterkere clubs.

2.4. Fysieke prestaties als voorspellende factor

Verschillende onderzoekers benadrukken het belang van fysieke prestatiegegevens. Moderne spelers worden voortdurend gemonitord via GPS-systemen en draagbare sensoren die loopafstanden, snelheden en intensiteit meten.

Een praktijkstudie bij de jeugdopleiding van De Silva et al., 2018 toont hoe tracking-data inzicht geven in fysieke belasting tijdens trainingen en wedstrijden. Deze gegevens helpen bij het optimaliseren van trainingsprogramma's en het begrijpen van positionele verschillen in fysieke inspanningen.

Daarnaast tonen Bongiovanni et al., 2021 aan dat lichaamskenmerken (zoals lengte en gewicht) via ML-modellen belangrijke voorspellers kunnen zijn van fysieke prestaties bij jeugdspelers. Dit bevestigt dat objectieve fysieke parameters bruikbaar zijn in talentidentificatie.

Ook Cortez et al., 2021 tonen aan dat fysiologische variabelen kunnen helpen bij het voorspellen van teamsucces. Hun ML-modellen identificeren welke fysieke kenmerken het sterkst bijdragen aan winnende prestaties. Deze studie bewijst dat het onderzoek naar de waarde van fysieke prestatie-indicatoren een meerwaarde kan bieden voor datagedreven scouting.

2.5. Voorspellende modellen voor prestaties en wedstrijden

ML wordt niet enkel gebruikt om individuele spelers te analyseren, maar ook om te voorspellen hoe teams presteren.

Zo vergelijken De Vulder, 2024 verschillende ML-modellen voor het voorspellen van wedstrijduitslagen, terwijl Almulla en Alam, 2020 aantonen welke spelersstatistieken het sterkst bijdragen aan winstkansen. Deze modellen gebruiken historische wedstrijddata om patronen te leren die verband houden met succes.

Trackingdata blijkt hierbij bijzonder waardevol. Fernández et al., 2016 tonen aan dat positiesdata van spelers tijdens wedstrijden kunnen worden gebruikt om prestaties te verklaren en te voorspellen. Ook Goes et al., 2019 bevestigen dat tactische en positionele statistieken bruikbaar zijn voor het voorspellen van wedstrijdresultaten. Verder richten Morciano et al., 2022 zich op het voorspellen van trainingsprestaties via ML-technieken, wat clubs helpt om spelersontwikkeling beter te monitoren.

2.6. Geavanceerde scoutingsystemen

Recent onderzoek focust op geïntegreerde scoutingsplatformen.

T R et al., 2024 introduceren een scoutingsysteem gebaseerd op *Expected Goals* (xG), een statistiek die de kwaliteit van scoringskansen meet. ML-modellen analyseren hierbij onderliggende prestatie-indicatoren om spelers objectief te vergelijken. Daarnaast stellen Bhatt et al., 2025 het KickClone-systeem voor, dat spelers vergelijkt via *Principal Component Analysis* (PCA). PCA is een techniek die grote hoeveelheden variabelen reduceert tot enkele kerncomponenten die de belangrijkste verschillen tussen spelers samenvatten.

De studie van Campos-Redondo et al., 2025 introduceert fysieke prestatieprofielen op basis van PCA-clustering. Hierbij worden spelers gegroepeerd volgens fysieke kenmerken in plaats van tactische posities, wat nieuwe inzichten biedt voor gepersonaliseerde training en scouting.

2.7. Conclusie van de literatuur

Uit de literatuur blijkt dat machine learning een belangrijke rol speelt in de evolutie naar objectieve en datagedreven scouting. Vooral fysieke en fysiologische spelersgegevens blijken waardevol voor prestatieanalyse en talentidentificatie. Verschillende studies tonen aan dat ML-modellen verborgen patronen kunnen detecteren die moeilijk waarneembaar zijn voor menselijke scouts.

Toch benadrukken meerdere auteurs dat datakwaliteit, standaardisatie en voldoende datasetgrootte cruciale voorwaarden zijn voor betrouwbare modellen. De combinatie van fysieke prestatie-indicatoren en voorspellende ML-technieken vormt een veelbelovende onderzoekslijn voor het objectiveren van spelersbeoordelingen bin-

nen professionele voetbalcontexten.

3

Methodologie

3.1. Onderzoeksopzet

Het doel van deze bachelorproef is het ontwikkelen van een interpreteerbare en reproduceerbare fysieke spelersscore ter ondersteuning van objectieve voetbalscouting. Om dit te realiseren wordt een data-gedreven methodologie gehanteerd waarbij machine learning-modellen worden ingezet om het relatieve belang van fysieke prestatie-indicatoren te bepalen.

Er wordt gekozen voor een hybride aanpak waarbij supervised learning gecombineerd wordt met model-interpretatietechnieken. Daarnaast worden positie-specifieke modellen ontwikkeld om vertekening ten gevolge van verschillende fysieke rolovereisten per positie te vermijden.

3.2. Dataset en variabelen

De dataset bestaat uit wedstrijdgerelateerde fysieke prestatie-indicatoren per speler per wedstrijd. Alle variabelen worden genormaliseerd per 90 minuten om onderlinge vergelijkbaarheid te garanderen.

Voorbeelden van gebruikte features zijn nog te bepalen.

Indien beschikbaar worden ook contextvariabelen zoals speelminuten meegenomen voor normalisatiecontrole.

3.3. Positie-specifieke modellering

Aangezien fysieke vereisten sterk verschillen per speelpositie, wordt de dataset opgesplitst per positie (bijvoorbeeld centrale verdedigers, flankverdedigers, centrale middenvelders en flankaanvallers). Voor elke positie wordt een afzonderlijk machine learning-model getraind.

Deze aanpak zorgt ervoor dat spelers uitsluitend worden vergeleken met positiegenoten, wat structurele bias in de scoreberekening voorkomt.

3.4. Supervised learning

Voor elke positie wordt een classificatiemodel ontwikkeld met als doelvariabele een proxy voor fysieke waarde binnen de ploeg. Als proxy wordt gekozen voor aantal speelminuten in volgende wedstrijd.

Er wordt gebruikgemaakt van een gradient boosting model (bijvoorbeeld XGBoost) om niet-lineaire relaties tussen fysieke variabelen en de doelvariabele te kunnen modelleren.

De dataset wordt opgesplitst in trainings- en testdata, waarbij cross-validatie wordt toegepast om overfitting te vermijden. Modelperformantie wordt geëvalueerd aan de hand van geschikte metrics, zoals accuracy, F1-score of RMSE, afhankelijk van het type doelvariabele.

3.5. Modelinterpretatie via SHAP

Om het relatieve belang van individuele fysieke variabelen te bepalen, wordt gebruikgemaakt van SHAP (SHapley Additive exPlanations). SHAP-waarden kwantificeren de bijdrage van elke feature aan de voorspelling van het model.

Voor elke speler wordt de gemiddelde absolute SHAP-waarde per feature berekend over meerdere wedstrijden. Deze waarden representeren de effectieve impact van fysieke prestaties op de modeloutput.

3.6. Constructie van de fysieke spelersscore

De fysieke spelersscore wordt geconstrueerd op basis van de geaggregeerde SHAP-waarden. Concreet wordt per speler:

1. De gemiddelde absolute SHAP-impact berekend over een vooraf bepaalde periode.
2. Deze impact genormaliseerd binnen de betreffende positie.
3. Geschaald naar een interpreteerbare score tussen 0 en 100.

De resulterende score weerspiegelt de relatieve fysieke bijdrage van een speler binnen zijn positie, op een reproduceerbare en data-gedreven manier.

3.7. Validatie van de score

De ontwikkelde fysieke score wordt geëvalueerd op basis van:

- Stabiliteit over meerdere wedstrijden

- Consistentie binnen positie
- Vergelijking met de huidige subjectieve fysieke beoordeling binnen de club

Deze validatie laat toe om de praktische bruikbaarheid van de voorgestelde methode te beoordelen en aanbevelingen te formuleren voor implementatie binnen de scoutingwerking.

4


Conclusie

Curabitur nunc magna, posuere eget, venenatis eu, vehicula ac, velit. Aenean ornare, massa a accumsan pulvinar, quam lorem laoreet purus, eu sodales magna risus molestie lorem. Nunc erat velit, hendrerit quis, malesuada ut, aliquam vitae, wisi. Sed posuere. Suspendisse ipsum arcu, scelerisque nec, aliquam eu, molestie tincidunt, justo. Phasellus iaculis. Sed posuere lorem non ipsum. Pellentesque dapibus. Suspendisse quam libero, laoreet a, tincidunt eget, consequat at, est. Nullam ut lectus non enim consequat facilisis. Mauris leo. Quisque pede ligula, auctor vel, pellentesque vel, posuere id, turpis. Cras ipsum sem, cursus et, facilisis ut, tempus euismod, quam. Suspendisse tristique dolor eu orci. Mauris mattis. Aenean semper. Vivamus tortor magna, facilisis id, varius mattis, hendrerit in, justo. Integer purus.

Vivamus adipiscing. Curabitur imperdiet tempus turpis. Vivamus sapien dolor, congue venenatis, euismod eget, porta rhoncus, magna. Proin condimentum pretium enim. Fusce fringilla, libero et venenatis facilisis, eros enim cursus arcu, vitae facilisis odio augue vitae orci. Aliquam varius nibh ut odio. Sed condimentum condimentum nunc. Pellentesque eget massa. Pellentesque quis mauris. Donec ut ligula ac pede pulvinar lobortis. Pellentesque euismod. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent elit. Ut laoreet ornare est. Phasellus gravida vulputate nulla. Donec sit amet arcu ut sem tempor malesuada. Praesent hendrerit augue in urna. Proin enim ante, ornare vel, consequat ut, blandit in, justo. Donec felis elit, dignissim sed, sagittis ut, ullamcorper a, nulla. Aenean pharetra vulputate odio.

Quisque enim. Proin velit neque, tristique eu, eleifend eget, vestibulum nec, lacus. Vivamus odio. Duis odio urna, vehicula in, elementum aliquam, aliquet laoreet, tellus. Sed velit. Sed vel mi ac elit aliquet interdum. Etiam sapien neque, convallis et, aliquet vel, auctor non, arcu. Aliquam suscipit aliquam lectus. Proin tincidunt magna sed wisi. Integer blandit lacus ut lorem. Sed luctus justo sed enim.

Morbi malesuada hendrerit dui. Nunc mauris leo, dapibus sit amet, vestibulum et, commodo id, est. Pellentesque purus. Pellentesque tristique, nunc ac pulvinar adipiscing, justo eros consequat lectus, sit amet posuere lectus neque vel augue. Cras consectetur libero ac eros. Ut eget massa. Fusce sit amet enim eleifend sem dictum auctor. In eget risus luctus wisi convallis pulvinar. Vivamus sapien risus, tempor in, viverra in, aliquet pellentesque, eros. Aliquam euismod libero a sem. Nunc velit augue, scelerisque dignissim, lobortis et, aliquam in, risus. In eu eros. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Curabitur vulputate elit viverra augue. Mauris fringilla, tortor sit amet malesuada mollis, sapien mi dapibus odio, ac imperdiet ligula enim eget nisl. Quisque vitae pede a pede aliquet suscipit. Phasellus tellus pede, viverra vestibulum, gravida id, laoreet in, justo. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Integer commodo luctus lectus. Mauris justo. Duis varius eros. Sed quam. Cras lacus eros, rutrum eget, varius quis, convallis iaculis, velit. Mauris imperdiet, metus at tristique venenatis, purus neque pellentesque mauris, a ultrices elit lacus nec tortor. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent malesuada. Nam lacus lectus, auctor sit amet, malesuada vel, elementum eget, metus. Duis neque pede, facilisis eget, egestas elementum, nonummy id, neque.



Onderzoeksvoorstel

Het onderwerp van deze bachelorproef is gebaseerd op een onderzoeksvoorstel dat vooraf werd beoordeeld door de promotor. Dat voorstel is opgenomen in deze bijlage.

A.1. Inleiding

Professionele voetbalclubs streven voortdurend naar sportieve en competitieve vooruitgang. In dit streven wordt steeds vaker gebruikgemaakt van data en technologie om spelersprestaties te monitoren, te evalueren en te optimaliseren. Door het gebruik van GPS-systemen, wearables en geavanceerde wedstrijdstatistieken beschikken clubs vandaag over een grote hoeveelheid objectieve fysieke prestatiegegevens.

Deze bachelorproef focust zich op het analyseren van fysieke spelersattributen binnen een wedstrijdcontext en onderzoekt hoe machine learning kan bijdragen aan het identificeren van fysiek relevante spelersprofielen. Door fysieke prestatiedata te koppelen aan wedstrijdresultaten wordt nagegaan welke fysieke kenmerken statistisch samenhangen met sportief succes. De doelgroep van dit onderzoek bestaat uit performance analisten en scouts binnen het professionele voetbal die nood hebben aan objectieve, interpreteerbare en data-gedreven ondersteuning bij scouting-beslissingen.

De centrale onderzoeksvraag van deze bachelorproef luidt: **In welke mate kunnen fysieke spelersstatistieken, geanalyseerd met explainable machine learning technieken, bijdragen aan het identificeren van relevante spelersprofielen voor voetbal scouting?**

Het doel van dit onderzoek is het ontwikkelen van een proof-of-concept dat aan-toont hoe machine learning en explainable AI kunnen worden ingezet om fysieke

prestatiedata te vertalen naar bruikbare inzichten voor scouting.

Enkele deelvragen met betrekking tot het probleemdomein zijn:

- Welke fysieke spelersattributen worden binnen professioneel voetbal relevant geacht voor prestaties en scouting?
- In welke mate vertonen fysieke spelersstatistieken een verband met wedstrijdresultaten?
- Welke contextuele factoren (positie, thuis/uit, competitieniveau) beïnvloeden de relevantie van fysieke attributen?

Enkele deelvragen met betrekking tot het oplossingsdomein zijn:

- Welke machine learning modellen zijn geschikt voor het voorspellen van wedstrijdresultaten op basis van fysieke data?
- Hoe kunnen explainable machine learning technieken worden toegepast om de bijdrage van fysieke attributen te interpreteren?
- Hoe kunnen deze inzichten vertaald worden naar praktische toepassingen binnen voetbal scouting?

A.2. Stand van zaken

De toepassing van data-analyse en machine learning binnen de sportwereld is de afgelopen jaren sterk toegenomen. In het bijzonder binnen professioneel voetbal worden steeds grotere hoeveelheden data verzameld, gaande van wedstrijd- en eventdata tot gedetailleerde fysieke prestatiedata afkomstig van GPS-systemen en wearables. Deze evolutie heeft geleid tot een groeiend onderzoeksdomein waarin machine learning technieken worden ingezet om sportprestaties te analyseren en te voorspellen.

Een recente systematische review van Pietraszewski et al. (2025) toont aan dat artificial intelligence en machine learning een steeds prominentere rol spelen binnen sport analytics. Volgens de auteurs worden deze technieken voornamelijk ingezet voor prestatie-evaluatie, wedstrijdvoorspelling en blessurepreventie. Hoewel het merendeel van de studies focust op technische en tactische indicatoren, benadrukt de review dat ook fysieke prestatiedata steeds vaker wordt opgenomen in voorspellende modellen. Dit onderstreept het potentieel van machine learning voor het analyseren van fysieke spelersattributen.

Binnen voetbalcontext wordt machine learning voornamelijk toegepast op wedstrijd- en eventdata. Pappalardo et al. (2018) introduceren met het PlayeRank-framework een data-gedreven methode om spelersprestaties te evalueren en te rangschikken. Hoewel dit framework voornamelijk technische en tactische statistieken gebruikt, illustreert het onderzoek hoe machine learning kan worden ingezet om multidimensionale spelersdata te vertalen naar objectieve evaluaties. Deze aanpak vormt

een belangrijke inspiratie voor het toepassen van data-gedreven methoden binnen scoutingprocessen.

Naast technische statistieken is er toenemende aandacht voor het gebruik van fysieke prestatiedata binnen machine learning modellen. Mandorino et al. (2023) tonen aan dat fysieke parameters zoals acceleraties, afstanden en intensieve acties succesvol kunnen worden geïntegreerd in machine learning modellen om de fysieke paraatheid van voetballers te kwantificeren. Dit bevestigt dat fysieke spelersstatistieken niet enkel relevant zijn voor load monitoring, maar ook waardevolle input vormen voor analytische modellen.

Machine learning wordt ook frequent ingezet voor het voorspellen van wedstrijdresultaten. In een studie binnen het *Journal of Big Data* tonen Mills et al. (2024) aan dat zowel klassieke machine learning modellen als meer geavanceerde technieken in staat zijn om voetbalwedstrijden te classificeren op basis van wedstrijdgerelateerde features. Hoewel fysieke statistieken in deze studie niet centraal staan, bevestigt het onderzoek dat match outcome prediction een geschikt kader vormt om de impact van specifieke featuregroepen, zoals fysieke teamkenmerken, te analyseren.

Een belangrijk aandachtspunt binnen sport analytics is de interpreteerbaarheid van machine learning modellen. In professionele omgevingen, zoals voetbal scouting, is het essentieel dat beslissingen niet enkel gebaseerd zijn op voorspellende prestaties, maar ook begrijpelijk en verantwoordbaar zijn. Calderón-Díaz et al. (2023) tonen aan dat explainable machine learning technieken, zoals feature importance en SHAP-waarden, inzicht kunnen bieden in de bijdrage van individuele fysieke kenmerken aan modelvoorspellingen. Hoewel hun onderzoek gericht is op blessurepredictie, is de gebruikte methodologie rechtstreeks toepasbaar op prestatie- en scoutinganalyses.

Tot slot benadrukken methodologische studies het belang van correcte dataverwerking en feature engineering binnen sport analytics. Davis et al. (2024) bespreken verschillende uitdagingen met betrekking tot datakwaliteit, aggregatie en evaluatie van machine learning modellen in sportcontexten. Deze uitdagingen zijn bijzonder relevant wanneer fysieke spelersdata wordt geaggregeerd naar teamniveau, zoals vereist is binnen wedstrijdanalyse en scoutinggerichte toepassingen.

Samenvattend toont de literatuur aan dat machine learning een waardevol instrument is binnen sport analytics, maar dat de toepassing van fysieke prestatiedata binnen scouting nog beperkt onderzocht is. Daarnaast blijkt interpreteerbaarheid een cruciale factor voor praktische toepasbaarheid. Deze bachelorproef sluit aan bij deze vaststellingen door fysieke spelersattributen centraal te stellen en explainable machine learning technieken toe te passen binnen een scoutingcontext.

A.3. Methodologie

Het onderzoek wordt uitgevoerd volgens een gestructureerde data science aanpak en bestaat uit meerdere fasen.

In een eerste fase wordt via literatuurstudie onderzocht welke fysieke spelersattributen relevant zijn binnen professioneel voetbal en hoe machine learning reeds wordt toegepast binnen sport analytics. Op basis hiervan wordt een selectie gemaakt van fysieke prestatie-indicatoren.

In de tweede fase wordt een dataset samengesteld bestaande uit wedstrijdgegevens, fysieke spelersstatistieken en wedstrijdresultaten over meerdere seizoenen. Individuele spelersstatistieken worden via feature engineering geaggregeerd naar teamniveau, rekening houdend met positie en speelminuten.

Vervolgens worden verschillende classificatiemodellen ontwikkeld om wedstrijdresultaten (winst, gelijkspel, verlies) te voorspellen op basis van deze fysieke team-features. Hierbij wordt gestart met een interpreteerbaar basismodel, gevolgd door complexere machine learning modellen.

In de laatste fase worden explainable machine learning technieken toegepast om de bijdrage van fysieke attributen aan de modelvoorspellingen te analyseren. De verkregen inzichten worden geïnterpreteerd in functie van voetbal scouting en vertaald naar concrete aanbevelingen.

A.4. Verwacht resultaat, conclusie

Er wordt verwacht dat dit onderzoek aantoont dat bepaalde fysieke spelersattributen een significante bijdrage leveren aan wedstrijdresultaten en dat deze attributen op een objectieve manier kunnen worden geïdentificeerd met behulp van machine learning. Daarnaast wordt verwacht dat explainable AI technieken toelaten om deze resultaten op een transparante en interpreteerbare manier te communiceren.

De bachelorproef zal aantonen dat fysieke prestatiedata niet enkel waardevol is voor trainingsopvolging, maar ook een relevante rol kan spelen binnen voetbal scouting. Het ontwikkelde proof-of-concept biedt een eerste stap richting data-gedreven scoutingbeslissingen waarbij objectieve fysieke profielen worden gecombineerd met menselijke expertise.

Bibliografie

- Almulla, J., & Alam, T. (2020). Machine Learning Models Reveal Key Performance Metrics of Football Players to Win Matches in Qatar Stars League. *IEEE Access*, 8, 213695–213705. <https://doi.org/10.1109/access.2020.3038601>
- Bhatt, R., Pandya, M., Raje, A., & Shah, P. (2025). KickClone: A Machine Learning Model Built to Revolutionize Football Scouting. *2025 International Conference on Artificial Intelligence and Machine Vision (AIMV)*, 1–9. <https://doi.org/10.1109/AIMV66517.2025.11203706>
- Bongiovanni, T., Trecroci, A., Cavaggioni, L., Rossi, A., Perri, E., Pasta, G., Iaia, F. M., & Alberti, G. (2021). Importance of anthropometric features to predict physical performance in elite youth soccer: a machine learning approach [PMID: 32835528]. *Research in Sports Medicine*, 29(3), 213–224. <https://doi.org/10.1080/15438627.2020.1809410>
- Calderón-Díaz, M., Aguirre, R. S., Váscquez, J. P., Yáñez, R., Roby, M., Querales, M., & Salas, R. (2023). Explainable Machine Learning Techniques to Predict Muscle Injuries in Professional Soccer Players through Biomechanical Analysis. *Sensors*, 24(1), 119. <https://doi.org/10.3390/s24010119>
- Campos-Redondo, A., Martínez-Sánchez, A., López-Sierra, P., Chacón-Fernández, E., & García-Rubio, J. (2025). Performance Profiles: A New Approach Based on Training Focused on Physical Aspects Rather than Technical-Tactical Ones. *Sports*, 13(11), 402. <https://doi.org/10.3390/sports13110402>
- Cortez, A., Trigo, A., & Loureiro, N. (2021, 1 januari). *Predicting Physiological Variables of Players that Make a Winning Football Team: A Machine Learning Approach*. https://doi.org/10.1007/978-3-030-86970-0_1
- Davis, J., Bransen, L., Devos, L., Jaspers, A., Meert, W., Robberechts, P., Haaren, J. V., & Roy, M. V. (2024). Methodology and evaluation in sports analytics: challenges, approaches, and lessons learned. *Machine Learning*. <https://doi.org/10.1007/s10994-024-06585-0>
- De Silva, V., Caine, M., Skinner, J., Dogan, S., Kondo, A., Peter, T., Axtell, E., Birnie, M., & Smith, B. (2018). Player Tracking Data Analytics as a Tool for Physical Performance Management in Football: A Case Study from Chelsea Football Club Academy. *Sports*, 6(4), 130. <https://doi.org/10.3390/sports6040130>
- De Vulder, R. (2024, januari). *Voorspelling van wedstrijduitslagen voor Club Brugge met Machine Learning: Een vergelijkende analyse van verschillende modellen*.

- Fernández, J., Medina, D., Gómez-Díaz, A., Arias, M., & Gavalda, R. (2016). From Training to Match Performance: A Predictive and Explanatory Study on Novel Tracking Data, 136–143. <https://doi.org/10.1109/ICDMW.2016.0027>
- Ghar, S., Patil, S., & Arunachalam, V. (2021). Data Driven football scouting assistance with simulated player performance extrapolation. *2021 20th IEEE International Conference on Machine Learning and Applications (ICMLA)*, 1160–1167. <https://doi.org/10.1109/ICMLA52953.2021.00189>
- Goes, F., Kempe, M., & Lemmink, K. (2019). Predicting match outcome in professional Dutch football using tactical performance metrics computed from position tracking data. *EasyChair preprint*. <https://doi.org/10.29007/4jjb>
- Liam, C. D. (2022, 20 september). *Is the Moneyball approach is a feasible approach for success in Football (Soccer)? An analysis of Brentford's adoption of a statistical approach*. <https://norma.ncirl.ie/id/eprint/5774>
- Mandorino, M., Tessitore, A., Leduc, C., Persichetti, V., Morabito, M., & Lacome, M. (2023). A New Approach to Quantify Soccer Players' Readiness through Machine Learning Techniques. *Applied Sciences*, 13(15), 8808. <https://doi.org/10.3390/app13158808>
- Mills, E. F. E. A., Deng, Z., Zhong, Z., & Li, J. (2024). Data-driven prediction of soccer outcomes using enhanced machine and deep learning techniques. *Journal Of Big Data*, 11(1). <https://doi.org/10.1186/s40537-024-01008-2>
- Morciano, G., Zingoni, A., Morachioli, A., & Calabrò, G. (2022). Machine Learning prediction of the expected performance of football player during training. *2022 IEEE International Conference on Metrology for Extended Reality, Artificial Intelligence and Neural Engineering (MetroXRINE)*, 574–578. <https://api.semanticscholar.org/CorpusID:254307452>
- Pappalardo, L., Cintia, P., Ferragina, P., Massucco, E., Pedreschi, D., & Giannotti, F. (2018). PlayeRank: data-driven performance evaluation and player ranking in soccer via a machine learning approach. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1802.04987>
- Pietraszewski, P., Terbalyan, A., Roczniok, R., Maszczyk, A., Ornowski, K., Manilewska, D., Kuliś, S., Zajac, A., & Gołaś, A. (2025). The Role of Artificial Intelligence in Sports Analytics: A Systematic Review and Meta-Analysis of Performance Trends. *Applied Sciences*, 15(13), 7254. <https://doi.org/10.3390/app15137254>
- Rico-González, M., Pino-Ortega, J., Méndez, A., Clemente, F., & Baca, A. (2022). Machine learning application in soccer: a systematic review. *Biology of Sport*, 40(1), 249–263. <https://doi.org/10.5114/biolsport.2023.112970>
- T R, P., Abhinav, B., Nandan, A., Gurikar, Adithya, Pandharkar, A., & Akshit. (2024). An xG Based Football Scouting System Using Machine Learning Techniques. <https://doi.org/10.1109/I2CT61223.2024.10544261>

- Vuorenmaa, H. (2025). *Artificial Intelligence Supporting Scouts and Sport Clubs in Player Recruitment*. <https://www.theseus.fi/handle/10024/893642>
- Yunus, M., & Aditya, R. S. (2024). Talent scouting and standardizing fitness data in football club: systematic review. *Retos*, 60, 1382–1389. <https://doi.org/10.47197/retos.v60.107767>